[TÊN TRƯỜNG/ĐƠN VỊ]
[KHOA/BỘ MÔN]

BÁO CÁO NGHIÊN CỨU KHOA HỌC

Triển khai mô hình AI trong lĩnh vực Chatbot/Trợ lý ảo

Ứng dụng kỹ thuật sinh tăng cường truy hồi (RAG) và tinh chỉnh
(fine-tuning) mô hình ngôn ngữ lớn nhằm trả lời thông minh, chính xác,
ngữ cảnh hóa dựa trên tài liệu và dữ liệu nội bộ
của Tổng công ty Bưu điện Việt Nam

Nhóm sinh viên thực hiện: [HỌ VÀ TÊN TÁC GIẢ]
Mã số sinh viên: [MSSV]
Giảng viên hướng dẫn: [HỌ VÀ TÊN GVHD]
Đơn vị phối hợp: Tổng công ty Bưu điện Việt Nam

[NĂM]

Lời cảm ơn

Em xin gửi lời cảm ơn chân thành tới [HỌ VÀ TÊN GVHD], người đã tận tình định hướng, góp ý và đồng hành cùng nhóm trong suốt quá trình nghiên cứu. Em cũng xin cảm ơn các anh chị kỹ sư tại Tổng công ty Bưu điện Việt Nam đã chia sẻ kiến thức nghiệp vụ, cung cấp bối cảnh bài toán và những phản hồi thực tiễn quý báu về hệ thống trợ lý ảo. Những kết quả trong báo cáo này một phần lớn dựa trên dữ liệu và hệ thống thử nghiệm nội bộ, mà nếu không có sự hỗ trợ đó thì đề tài khó có thể hoàn thành.

Do thời gian và năng lực còn hạn chế, báo cáo khó tránh khỏi thiếu sót. Em rất mong nhận được sự góp ý của thầy cô và các anh chị để đề tài được hoàn thiện hơn.

Nhóm thực hiện

[HỌ VÀ TÊN TÁC GIẢ]

Tóm tắt

Trong bối cảnh chuyển đổi số của ngành bưu chính, Tổng công ty Bưu điện Việt Nam (VNPost) sở hữu một khối lượng lớn tài liệu nghiệp vụ nội bộ: quy trình, quyết định, biểu phí dịch vụ, quy định về hàng hóa và chính sách bồi thường, cùng các nghiệp vụ tra cứu bưu gửi và bưu cục. Việc tra cứu thủ công tốn nhiều thời gian, trong khi các kênh hỏi đáp truyền thống khó đáp ứng nhu cầu tra cứu tức thời, chính xác và có trích nguồn. Báo cáo này nghiên cứu việc triển khai một trợ lý ảo thông minh dựa trên mô hình ngôn ngữ lớn (LLM) kết hợp kỹ thuật sinh tăng cường truy hồi (Retrieval-Augmented Generation – RAG) và tinh chỉnh (fine-tuning), hướng tới câu trả lời chính xác, ngữ cảnh hóa và bám sát tài liệu nội bộ.

Về phương pháp, đề tài khảo sát cơ sở lý thuyết về LLM, RAG và fine-tuning; thiết kế kiến trúc trợ lý ảo đa tác tử (multi-agent) gồm một tác tử điều phối và các tác tử chuyên biệt, giao tiếp qua các giao thức MCP và A2A; triển khai pipeline RAG lai (hybrid) kết hợp truy hồi thưa BM25 và truy hồi dày (dense) trên cơ sở dữ liệu vector Qdrant, kèm mô hình xếp hạng lại (reranker); đồng thời đề xuất pipeline fine-tuning theo hướng tham số hiệu quả (LoRA/QLoRA). Toàn bộ mô hình được phục vụ cục bộ (on-premise) bằng vLLM để bảo đảm dữ liệu nội bộ không rời khỏi hạ tầng của VNPost.

Kết quả thực nghiệm trên các tập tài liệu nội bộ và bộ đánh giá gồm 99 câu hỏi cho thấy truy hồi dày đạt Recall@20 = 100%, trong khi cấu hình sản xuất sau xếp hạng lại đạt Recall@5 = 50% và MRR = 0,3149; phân tích lỗi cho thấy nguyên nhân chính nằm ở khâu xếp hạng lại chứ không phải khâu truy hồi. Đề tài cũng trình bày kết quả đánh giá sinh văn bản bằng LLM-as-judge và bộ thước đo RAGAS, kết quả đo hiệu năng suy luận của vLLM, ước tính hiệu quả kinh tế – xã hội, và đề xuất kiến trúc lai RAG + fine-tuning cùng lộ trình phát triển. Kết quả cho thấy RAG là giải pháp phù hợp và khả thi cho tri thức động, còn fine-tuning bổ trợ cho phong cách và nghiệp vụ ổn định, và sự kết hợp của hai hướng tiếp cận mang lại giá trị thực tiễn cao cho Tổng công ty Bưu điện Việt Nam.

Từ khóa: trợ lý ảo, chatbot, mô hình ngôn ngữ lớn, RAG, fine-tuning, LoRA, truy hồi lai, reranker, multi-agent, VNPost.

Abstract

In the context of digital transformation in the postal sector, Vietnam Post (VNPost) holds a large corpus of internal business documents, including procedures, decisions, service tariffs, regulations on prohibited goods, and compensation policies, together with shipment-tracking and post-office look-up operations. Manual retrieval is time-consuming, and traditional support channels struggle to deliver instant, accurate, and source-grounded answers. This report studies the deployment of an intelligent virtual assistant based on large language models (LLMs) combined with Retrieval-Augmented Generation (RAG) and fine-tuning, aiming at accurate, context-aware, and document-grounded responses.

Methodologically, we review the theory of LLMs, RAG, and fine-tuning; design a multi-agent assistant architecture with a host orchestrator and specialist agents communicating via the MCP and A2A protocols; implement a hybrid RAG pipeline combining sparse BM25 and dense retrieval over a Qdrant vector store with a cross-encoder reranker; and propose a parameter-efficient fine-tuning pipeline (LoRA/QLoRA). All models are served on-premise with vLLM so that internal data never leaves VNPost infrastructure.

Experiments on internal corpora and a 99-question evaluation set show dense retrieval reaching Recall@20 = 100%, while the production configuration after reranking reaches Recall@5 = 50% with MRR = 0.3149; error analysis attributes the main loss to the reranking stage rather than retrieval. We further report LLM-as-judge and RAGAS-based generation evaluation, vLLM inference benchmarks, socio-economic impact estimates, and a hybrid RAG + fine-tuning architecture with a development roadmap. The results indicate that RAG is a suitable and feasible solution for dynamic knowledge, whereas fine-tuning complements it for stable style and domain behavior; their combination delivers high practical value for Tổng công ty Bưu điện Việt Nam.

Keywords: virtual assistant, chatbot, large language model, RAG, fine-tuning, LoRA, hybrid retrieval, reranker, multi-agent, Vietnam Post.

Danh mục từ viết tắt

Từ viết tắt	Diễn giải
A2A	Agent-to-Agent protocol – giao thức giao tiếp giữa các tác tử
API	Application Programming Interface – giao diện lập trình ứng dụng
BM25	Best Matching 25 – hàm xếp hạng truy hồi thưa dựa trên xác suất
CoT	Chain-of-Thought – chuỗi suy luận trong nhắc lệnh
CSKH	Chăm sóc khách hàng
DPO	Direct Preference Optimization – tối ưu hóa theo sở thích trực tiếp
DPR	Dense Passage Retrieval – truy hồi đoạn văn dày
EMS	Express Mail Service – dịch vụ chuyển phát nhanh
FP8	Định dạng số thực dấu phẩy động 8 bit
GPU	Graphics Processing Unit – đơn vị xử lý đồ họa
K8s	Kubernetes – nền tảng điều phối container
LLM	Large Language Model – mô hình ngôn ngữ lớn
LoRA	Low-Rank Adaptation – thích ứng hạng thấp
MCP	Model Context Protocol – giao thức ngữ cảnh mô hình
MLflow	Nền tảng quản lý vòng đời học máy
MRR	Mean Reciprocal Rank – nghịch đảo thứ hạng trung bình
nDCG	normalized Discounted Cumulative Gain
OCR	Optical Character Recognition – nhận dạng ký tự quang học
OTel	OpenTelemetry – chuẩn quan sát hệ thống
PEFT	Parameter-Efficient Fine-Tuning – tinh chỉnh hiệu quả tham số
PII	Personally Identifiable Information – thông tin định danh cá nhân
QLoRA	Quantized LoRA – LoRA trên mô hình lượng tử hóa

Từ viết tắt	Diễn giải
Qdrant	Cơ sở dữ liệu vector mã nguồn mở
RAG	Retrieval-Augmented Generation – sinh tăng cường truy hồi
RAGAS	Framework đánh giá RAG tự động
RBAC	Role-Based Access Control – kiểm soát truy cập theo vai trò
RLHF	Reinforcement Learning from Human Feedback
SFT	Supervised Fine-Tuning – tinh chỉnh có giám sát
SSO	Single Sign-On – đăng nhập một lần
VNPost	Tổng công ty Bưu điện Việt Nam
vLLM	Thư viện phục vụ suy luận LLM hiệu năng cao

Mục lục

Lời cảm ơn **1**

Tóm tắt **2**

Abstract **3**

Danh mục từ viết tắt **4**

1 Giới thiệu **12**
1.1 Bối cảnh và lý do chọn đề tài 12
1.2 Mục tiêu nghiên cứu 13
1.3 Đối tượng và phạm vi nghiên cứu 14
1.3.1 Đối tượng nghiên cứu 14
1.3.2 Phạm vi nghiên cứu 14
1.4 Phương pháp nghiên cứu 15
1.5 Đóng góp của đề tài 15
1.6 Cấu trúc báo cáo 16

2 Cơ sở lý thuyết và tổng quan **17**
2.1 Chatbot và trợ lý ảo 17
2.1.1 Khái niệm và phân loại 17
2.1.2 Trợ lý ảo và kiến trúc hội thoại 18
2.2 Mô hình ngôn ngữ lớn 18
2.2.1 Kiến trúc Transformer 18
2.2.2 Tokenization và biểu diễn từ 19
2.2.3 Quá trình huấn luyện 19
2.2.4 Sinh văn bản và nhắc lệnh 20
2.3 Sinh tăng cường truy hồi (RAG) 20
2.3.1 Khái niệm và động lực 20
2.3.2 Kiến trúc tổng quát 20
2.3.3 Chia đoạn và tiền xử lý tài liệu 20
2.3.4 Nhúng vector và cơ sở dữ liệu vector 21
2.3.5 Truy hồi thưa, truy hồi dày và truy hồi lai 21
2.3.6 Xếp hạng lại 22

2.3.7 Các biến thể của RAG 23
2.4 Tinh chỉnh mô hình ngôn ngữ lớn (Fine-tuning) 23
2.4.1 Khái niệm và các mức độ 23
2.4.2 Tinh chỉnh có giám sát và căn chỉnh 23
2.4.3 LoRA 23
2.4.4 QLoRA 24
2.4.5 Khi nào nên dùng fine-tuning 24
2.5 So sánh RAG và fine-tuning, kiến trúc lai 24
2.6 Các thước đo đánh giá 25
2.6.1 Thước đo truy hồi 25
2.6.2 Thước đo sinh văn bản 26
2.7 Nền tảng triển khai 26
2.7.1 Phục vụ suy luận với vLLM 26
2.7.2 Lượng tử hóa FP8 26
2.7.3 Giao thức MCP và A2A 27
2.7.4 Quan sát hệ thống và quản lý prompt 27
Kết chương 27

3 Kiến trúc hệ thống đề xuất 28
3.1 Đặc thù bài toán tại VNPost 28
3.1.1 Đặc điểm dữ liệu nội bộ 28
3.1.2 Các nhóm nghiệp vụ 29
3.2 Yêu cầu chức năng và phi chức năng 29
3.2.1 Yêu cầu chức năng 29
3.2.2 Yêu cầu phi chức năng 29
3.3 Kiến trúc tổng thể đa tác tử 29
3.4 Pipeline RAG chi tiết 30
3.4.1 Pha lập chỉ mục 30
3.4.2 Pha truy hồi và sinh 31
3.4.3 Tham số hóa và cấu hình 31
3.5 Pipeline fine-tuning đề xuất 31
3.5.1 Thu thập và chuẩn bị dữ liệu 33
3.5.2 Cấu hình LoRA/QLoRA 33
3.6 Kiến trúc lai RAG + Fine-tuning 34
3.7 Hạ tầng và bảo mật 35
3.7.1 Hạ tầng phục vụ 35
3.7.2 Bảo mật dữ liệu 35

Kết chương 35

4 Triển khai thực nghiệm 36
4.1 Môi trường và công cụ 36
4.2 Dữ liệu 37
4.2.1 Các kho tài liệu 37
4.2.2 Bộ đánh giá 37
4.2.3 Tiền xử lý 37
4.3 Cài đặt RAG 38
4.3.1 Chia đoạn và nhúng 38
4.3.2 Cấu hình truy hồi 38
4.3.3 Nhúng câu hỏi và prompt 38
4.4 Thiết kế fine-tuning 39
4.5 Triển khai đa tác tử 39
4.5.1 Tác tử điều phối 39
4.5.2 Các tác tử chuyên biệt và công cụ 39
4.5.3 Quy tắc định tuyến 40
4.6 Hệ thống quan sát và quản lý prompt 40
4.7 Khó khăn và giải pháp 40
Kết chương 40

5 Kết quả và đánh giá 42
5.1 Phương pháp đánh giá 42
5.2 Kết quả truy hồi 43
5.2.1 Kết quả tổng hợp 43
5.2.2 Phân tích lỗi 44
5.3 Kết quả sinh văn bản và đánh giá agent 44
5.3.1 Đánh giá bởi LLM-as-judge 44
5.3.2 Đánh giá RAGAS trên bộ 99 câu hỏi EMS 44
5.4 So sánh RAG, fine-tuning và kiến trúc lai 45
5.5 Hiệu năng hệ thống 46
5.6 Case study định tính 47
5.7 Hiệu quả kinh tế – xã hội 47
5.8 Thảo luận 48
5.8.1 Ưu điểm 48
5.8.2 Hạn chế 48
5.8.3 Tính khái quát 48
Kết chương 49

6 Kết luận và hướng phát triển **50**
6.1 Kết luận 50
6.2 Hạn chế 51
6.3 Hướng phát triển 51
Kết chương 52

A Prompt hệ thống mẫu **53**
A.1. Prompt tác tử điều phối 53
A.2. Prompt tác tử RAG 53

B Bảng cấu hình tham số **55**

C Danh mục mô hình và thành phần **56**

D Mẫu hội thoại minh họa **57**

Danh sách hình vẽ

2.1 Sơ đồ khối một khối Transformer (một lớp) với self-attention và feed-forward. 19
2.2 Kiến trúc tổng quát của một hệ thống RAG. 21
2.3 Pipeline lập chỉ mục tài liệu trong hệ thống RAG. 21
2.4 Pipeline truy hồi lai kết hợp BM25, truy hồi dày và xếp hạng lại. 22
2.5 Minh họa LoRA: giữ nguyên W_0 và thêm cập nhật hạng thấp BA. 24

3.1 Kiến trúc đa tác tử: host điều phối các tác tử chuyên biệt qua A2A. 30
3.2 Pipeline RAG đầy đủ từ lập chỉ mục đến sinh câu trả lời. 32
3.3 Pipeline fine-tuning đề xuất cho trợ lý ảo VNPost. 33
3.4 Kiến trúc lai: bộ định tuyến chọn RAG, mô hình tinh chỉnh hoặc kết hợp. 34

5.1 So sánh Recall giữa các cấu hình truy hồi. 43
5.2 Thông lượng phục vụ lô của các cấu hình vLLM. 46

Danh sách bảng

2.1 So sánh RAG và fine-tuning theo các tiêu chí triển khai. 25

4.1 Các công cụ và thành phần chính của hệ thống. 36
4.2 Thống kê các kho tài liệu sử dụng trong thực nghiệm. 37
4.3 Cấu hình tham số truy hồi RAG. 38
4.4 Cấu hình LoRA/QLoRA đề xuất cho fine-tuning. 39
4.5 Khó khăn gặp phải và giải pháp áp dụng. 41

5.1 Kết quả truy hồi trên bộ mẫu (6 câu hỏi). 43
5.2 Kết quả minh họa các thước đo RAGAS trên bộ 99 câu hỏi EMS. 45
5.3 So sánh RAG, fine-tuning và kiến trúc lai trong bối cảnh VNPost. 45
5.4 Kết quả đo thông lượng suy luận vLLM. 46
5.5 Ước lượng hiệu quả kinh tế của giải pháp. 48

B.1 Cấu hình tham số tổng hợp của hệ thống. 55

C.1 Các mô hình và thành phần chính được sử dụng. 56

Chương 1

Giới thiệu

1.1 Bối cảnh và lý do chọn đề tài

Trong những năm gần đây, chuyển đổi số đã trở thành một trong những định hướng chiến lược trọng tâm của ngành bưu chính – viễn thông Việt Nam. Tổng công ty Bưu điện Việt Nam (Tổng công ty Bưu điện Việt Nam, sau đây gọi tắt là VNPost) vận hành một mạng lưới rộng khắp với hàng nghìn điểm phục vụ, hàng chục nghìn lao động và một danh mục dịch vụ đa dạng: bưu chính, chuyển phát nhanh (EMS), logistics, tài chính bưu chính và các dịch vụ công. Song song với hoạt động vận hành, VNPost sở hữu một khối lượng tài liệu nghiệp vụ nội bộ rất lớn, bao gồm quy trình nghiệp vụ, quyết định, công văn hướng dẫn, biểu phí dịch vụ, quy định về hàng hóa cấm gửi, chính sách bồi thường và các tiêu chuẩn chất lượng phát.

Thực tế vận hành cho thấy việc tra cứu thủ công khối tài liệu này tiêu tốn đáng kể thời gian của cán bộ công nhân viên. Khi một khách hàng hỏi về cước phí EMS, thời gian toàn trình, quy định về hàng hóa đặc biệt hay chính sách bồi thường, nhân viên phải mở nhiều văn bản khác nhau, tìm đúng điều khoản, rồi tổng hợp câu trả lời. Các kênh hỏi đáp truyền thống như danh mục câu hỏi thường gặp (FAQ) hoặc tổng đài chỉ có thể đáp ứng một phần nhu cầu: FAQ cứng nhắc và nhanh lỗi thời, còn tổng đài phụ thuộc vào số lượng nhân viên và thời gian làm việc. Hệ quả là trải nghiệm khách hàng bị ảnh hưởng và chi phí vận hành tăng lên.

Sự phát triển của các mô hình ngôn ngữ lớn (Large Language Model – LLM) mở ra một hướng giải quyết mới. Với khả năng hiểu ngôn ngữ tự nhiên và sinh văn bản mạch lạc, LLM có thể đóng vai trò lõi của một trợ lý ảo có khả năng hội thoại tự nhiên. Tuy nhiên, bản thân một LLM tổng quát không thể trả lời chính xác về tài liệu nội bộ của một tổ chức cụ thể: nó không được huấn luyện trên dữ liệu đó, dễ sinh thông tin sai lệch (hiện tượng “ảo giác”), và không thể trích dẫn nguồn để người dùng kiểm chứng. Hai hướng tiếp cận chính được cộng đồng nghiên cứu và công nghiệp áp dụng để khắc phục hạn chế này là:

- **Sinh tăng cường truy hồi (Retrieval-Augmented Generation – RAG):** tách tri thức ra khỏi tham số mô hình, truy hồi các đoạn tài liệu liên quan từ một kho tri thức bên ngoài tại thời điểm suy luận, rồi đưa chúng vào ngữ cảnh để mô hình sinh câu trả lời có căn cứ và có thể trích nguồn.
- **Tinh chỉnh (fine-tuning):** tiếp tục huấn luyện mô hình trên dữ liệu chuyên ngành để điều chỉnh hành vi, phong cách và kiến thức miền, giúp mô hình trả lời đúng "giọng" nghiệp vụ và định dạng mong muốn.

Đối với một tổ chức như VNPost, bài toán đặt ra không chỉ là kỹ thuật mà còn là bảo mật dữ liệu: tài liệu nghiệp vụ nội bộ và thông tin khách hàng không được phép rời khỏi hạ tầng của Tổng công ty. Điều này dẫn tới yêu cầu triển khai mô hình cục bộ (on-premise) thay vì gọi các dịch vụ đám mây bên ngoài. Báo cáo này xuất phát từ chính những yêu cầu thực tiễn đó: nghiên cứu và triển khai một trợ lý ảo thông minh cho VNPost, kết hợp RAG và fine-tuning, có khả năng trả lời chính xác, ngữ cảnh hóa dựa trên tài liệu nội bộ, vận hành an toàn trên hạ tầng riêng và có thể mở rộng theo nhu cầu nghiệp vụ.

1.2 Mục tiêu nghiên cứu

Đề tài hướng tới các mục tiêu sau:

1. Hệ thống hóa cơ sở lý thuyết về chatbot/trợ lý ảo, mô hình ngôn ngữ lớn, kỹ thuật RAG và kỹ thuật fine-tuning, làm rõ ưu nhược điểm và phạm vi áp dụng của từng hướng tiếp cận.
2. Thiết kế một kiến trúc trợ lý ảo đa tác tử (multi-agent) phù hợp với đặc thù dữ liệu và nghiệp vụ của VNPost, trong đó các tác tử chuyên biệt đảm nhận các miền nghiệp vụ khác nhau và giao tiếp qua các giao thức chuẩn hóa.
3. Triển khai và thực nghiệm một pipeline RAG lai kết hợp truy hồi thưa BM25 và truy hồi dày trên cơ sở dữ liệu vector, có bước xếp hạng lại, nhằm tạo câu trả lời bám sát tài liệu.
4. Đề xuất và mô tả một pipeline fine-tuning theo hướng tham số hiệu quả (LoRA/QLoRA), cùng tiêu chí quyết định khi nào nên dùng RAG, khi nào nên dùng mô hình đã tinh chỉnh, và cách kết hợp hai hướng tiếp cận trong một kiến trúc lai.

5. Đánh giá hệ thống bằng các thước đo định lượng (Recall@k, MRR, các thước đo RAGAS, đánh giá bởi mô hình ngôn ngữ) và định tính (case study hội thoại), từ đó rút ra bài học triển khai và đề xuất lộ trình phát triển.

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các phương pháp và kiến trúc triển khai trợ lý ảo dựa trên mô hình ngôn ngữ lớn cho miền nghiệp vụ bưu chính, cụ thể là kỹ thuật RAG và kỹ thuật fine-tuning, cùng các thành phần hỗ trợ như nhúng (embedding), cơ sở dữ liệu vector, xếp hạng lại và hạ tầng phục vụ mô hình.

1.3.2 Phạm vi nghiên cứu

Đề tài tập trung vào miền dữ liệu và nghiệp vụ của VNPost, bao gồm:

- **Tài liệu văn thư và quy trình nội bộ:** các quyết định, công văn, quy trình nghiệp vụ (tập thử nghiệm gồm 17 tài liệu văn thư đại diện).
- **Tài liệu sản phẩm – dịch vụ:** biểu phí, quy định hàng hóa cấm gửi, chính sách bồi thường, thời gian toàn trình (tập thử nghiệm gồm 119 tài liệu).
- **Tài liệu dịch vụ chuyển phát nhanh EMS:** các quyết định biểu phí, quy định hàng hóa đặc biệt, chính sách bồi thường EMS (khoảng 30 tài liệu).
- **Nghiệp vụ tra cứu:** tra cứu tình trạng bưu gửi, tra cứu thông tin bưu cục, và tra cứu chất lượng phát.
- **Bộ đánh giá:** bộ gồm 99 cặp câu hỏi – đáp án tham chiếu cho miền EMS.

Về mặt kỹ thuật, đề tài giới hạn ở các mô hình mã nguồn mở phục vụ cục bộ, không sử dụng các mô hình thương mại qua API đám mây, nhằm bảo đảm yêu cầu bảo mật dữ liệu nội bộ.

1.4 Phương pháp nghiên cứu

Đề tài sử dụng kết hợp nhiều phương pháp:

1. **Nghiên cứu tài liệu:** khảo sát các công trình khoa học và tài liệu kỹ thuật về Transformer, RAG, fine-tuning, LoRA/QLoRA, các thước đo đánh giá và hạ tầng phục vụ suy luận, nhằm xây dựng nền tảng lý thuyết và lựa chọn công nghệ.
2. **Phân tích và thiết kế hệ thống:** phân tích yêu cầu nghiệp vụ của VNPost, từ đó thiết kế kiến trúc đa tác tử, pipeline RAG và pipeline fine-tuning cùng kiến trúc lai.
3. **Thực nghiệm:** triển khai hệ thống thử nghiệm, xây dựng các pipeline xử lý dữ liệu – từ nhận dạng ký tự quang học (OCR), chuẩn hóa tài liệu, chia đoạn, nhúng vector, đến truy hồi lai và xếp hạng lại; tiến hành đo đạc trên dữ liệu nội bộ.
4. **Đánh giá định lượng:** sử dụng các thước đo truy hồi (Recall@k, MRR), các thước đo sinh văn bản (bộ thước đo RAGAS) và đánh giá bởi mô hình ngôn ngữ (LLM-as-judge); đo hiệu năng suy luận của hệ thống phục vụ.
5. **Đánh giá định tính:** phân tích các tình huống hội thoại thực tế, đánh giá mức độ hữu ích của câu trả lời và tính khả thi khi triển khai ở quy mô lớn.
6. **Ước lượng hiệu quả:** ước tính lợi ích kinh tế – xã hội dựa trên thời gian tiết kiệm được của người dùng so với quy trình thủ công.

1.5 Đóng góp của đề tài

Các đóng góp chính của đề tài bao gồm:

- **Về lý thuyết:** cung cấp một bức tranh tổng hợp, có hệ thống về RAG và fine-tuning trong bối cảnh triển khai trợ lý ảo doanh nghiệp, đặc biệt nhấn mạnh sự đánh đổi giữa tri thức động và hành vi miền, làm cơ sở cho kiến trúc lai.
- **Về kiến trúc:** đề xuất một kiến trúc trợ lý ảo đa tác tử kết hợp RAG lai và fine-tuning cho miền bưu chính, có khả năng mở rộng và bảo đảm dữ liệu nội bộ không rời khỏi hạ tầng tổ chức.
- **Về thực nghiệm:** triển khai và đo đạc trên dữ liệu và nghiệp vụ thực tế của VNPost, cung cấp bằng chứng định lượng về hiệu quả của từng

thành phần (truy hồi thưa, truy hồi dày, xếp hạng lại) và chỉ ra điểm nghẽn cần cải thiện.

- **Về đánh giá:** xây dựng quy trình đánh giá kết hợp thước đo truy hồi, thước đo RAGAS và đánh giá bởi LLM, phù hợp với đặc thù tiếng Việt và miền nghiệp vụ hẹp.
- **Về thực tiễn:** đề xuất lộ trình triển khai và ước lượng hiệu quả kinh tế, giúp tổ chức ra quyết định đầu tư và mở rộng hệ thống.

1.6 Cấu trúc báo cáo

Ngoài phần mở đầu và phụ lục, báo cáo được tổ chức thành sáu chương:

Chương 1 – Giới thiệu: trình bày bối cảnh, mục tiêu, đối tượng, phạm vi, phương pháp nghiên cứu, đóng góp và cấu trúc báo cáo.

Chương 2 – Cơ sở lý thuyết và tổng quan: hệ thống hóa kiến thức về chatbot, mô hình ngôn ngữ lớn, RAG, fine-tuning, kiến trúc lai, các thước đo đánh giá và nền tảng triển khai.

Chương 3 – Kiến trúc hệ thống đề xuất: phân tích bài toán, yêu cầu và thiết kế kiến trúc đa tác tử, pipeline RAG, pipeline fine-tuning và kiến trúc lai cho VNPost.

Chương 4 – Triển khai thực nghiệm: mô tả môi trường, dữ liệu, cấu hình RAG, thiết kế fine-tuning, triển khai đa tác tử và hệ thống quan sát.

Chương 5 – Kết quả và đánh giá: trình bày kết quả truy hồi, kết quả sinh văn bản, so sánh các hướng tiếp cận, hiệu năng hệ thống, case study và hiệu quả kinh tế – xã hội.

Chương 6 – Kết luận và hướng phát triển: tóm tắt kết quả, nêu hạn chế và đề xuất hướng phát triển.

Phần cuối báo cáo gồm tài liệu tham khảo và các phụ lục (prompt mẫu, bảng cấu hình tham số và danh mục mô hình).

Chương 2

Cơ sở lý thuyết và tổng quan

Chương này hệ thống hóa các kiến thức nền tảng cần thiết cho đề tài. Trước hết, mục 2.1 giới thiệu khái niệm chatbot và trợ lý ảo. Mục 2.2 trình bày mô hình ngôn ngữ lớn và kiến trúc Transformer. Mục 2.3 và mục 2.4 lần lượt đi sâu vào hai kỹ thuật trọng tâm là sinh tăng cường truy hồi (RAG) và tinh chỉnh (fine-tuning). Mục 2.5 so sánh hai hướng tiếp cận và đề xuất kiến trúc lai. Mục 2.6 trình bày các thước đo đánh giá, và mục 2.7 giới thiệu các nền tảng triển khai thực tế.

2.1 Chatbot và trợ lý ảo

2.1.1 Khái niệm và phân loại

Chatbot là một chương trình máy tính được thiết kế để tương tác với con người thông qua hội thoại ngôn ngữ tự nhiên. Có thể phân loại chatbot theo nhiều tiêu chí. Theo mức độ phức tạp của cơ chế xử lý, chatbot được chia thành ba thế hệ:

- **Chatbot dựa trên luật (rule-based):** hoạt động theo các kịch bản và mẫu câu lệnh được định nghĩa trước. Ưu điểm là dễ kiểm soát và tiên đoán, nhưng cứng nhắc, khó mở rộng và dễ thất bại trước các cách diễn đạt ngoài kịch bản.
- **Chatbot dựa trên học máy (retrieval-based / intent-based):** sử dụng các mô hình phân loại ý định và trích xuất thực thể để ánh xạ câu hỏi người dùng vào một tập câu trả lời định sẵn. Linh hoạt hơn rule-based nhưng vẫn phụ thuộc vào tập ý định hữu hạn.
- **Chatbot sinh văn bản (generative) dựa trên mô hình ngôn ngữ lớn:** sinh câu trả lời trực tiếp từ mô hình ngôn ngữ, có khả năng diễn đạt tự nhiên và xử lý câu hỏi mở. Đây là hướng tiếp cận mà đề tài lựa chọn.

2.1.2 Trợ lý ảo và kiến trúc hội thoại

Khái niệm "trợ lý ảo" (virtual assistant) thường được hiểu rộng hơn chatbot: không chỉ trả lời câu hỏi mà còn có khả năng thực hiện tác vụ, gọi công cụ, truy cập hệ thống nghiệp vụ và duy trì ngữ cảnh qua nhiều lượt hội thoại. Một trợ lý ảo hiện đại thường gồm các thành phần: (i) bộ hiểu ngôn ngữ và quản lý hội thoại; (ii) bộ truy xuất tri thức; (iii) bộ gọi công cụ (tool calling); (iv) bộ sinh câu trả lời; và (v) lớp quan sát, ghi log để giám sát chất lượng.

Trong các hệ thống lớn, kiến trúc *đa tác tử* (multi-agent) ngày càng phổ biến: một tác tử điều phối (orchestrator/host) tiếp nhận yêu cầu người dùng và định tuyến đến các tác tử chuyên biệt (specialist agents), mỗi tác tử phụ trách một miền nghiệp vụ hẹp. Cách tổ chức này giúp hệ thống dễ mở rộng, dễ kiểm thử và giảm tải nhận thức cho từng thành phần. Để các tác tử có thể giao tiếp và chia sẻ công cụ một cách chuẩn hóa, các giao thức như Model Context Protocol (MCP) và Agent-to-Agent (A2A) được sử dụng (trình bày ở mục 2.7).

2.2 Mô hình ngôn ngữ lớn

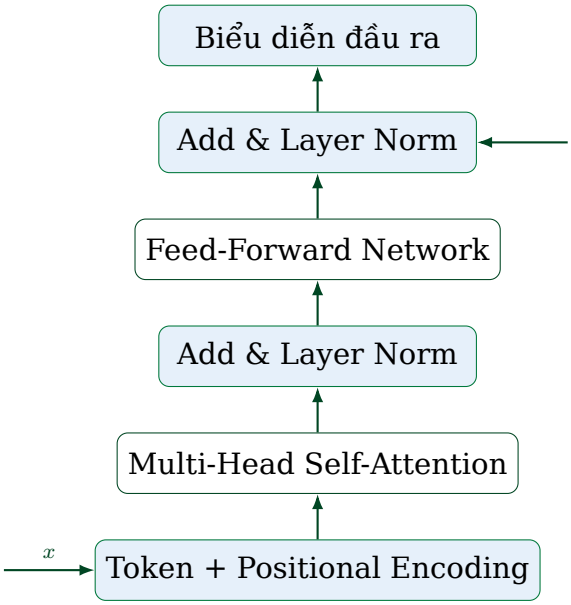
2.2.1 Kiến trúc Transformer

Hầu hết các mô hình ngôn ngữ lớn hiện đại đều dựa trên kiến trúc Transformer [1]. Khác với mạng hồi tiếp (RNN) xử lý tuần tự từng token, Transformer xử lý toàn bộ chuỗi song song nhờ cơ chế *tự chú ý* (self-attention), cho phép mô hình nắm bắt quan hệ giữa các token ở xa nhau một cách hiệu quả và song song hóa tốt trên GPU.

Cơ chế tự chú ý được mô tả bằng công thức *scaled dot-product attention*:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V, \tag{2.1}$$

trong đó Q, K, V lần lượt là các ma trận truy vấn (query), khóa (key) và giá trị (value) được chiếu tuyến tính từ biểu diễn đầu vào, và d_k là số chiều của vector khóa. Cơ chế *đa đầu* (multi-head attention) chạy song song nhiều phép chú ý trên các không gian con khác nhau rồi ghép kết quả, giúp mô hình học nhiều loại quan hệ đồng thời. Mỗi khối Transformer còn gồm mạng truyền thẳng theo vị trí (position-wise feed-forward network), chuẩn hóa lớp (layer normalization) và kết nối tắt (residual connection). Thông tin vị trí của token được bổ sung qua positional encoding.



Hình 2.1: Sơ đồ khối một khối Transformer (một lớp) với self-attention và feed-forward.

2.2.2 Tokenization và biểu diễn từ

Trước khi đưa vào mô hình, văn bản được chia thành các *token* bằng bộ tokenizer (thường theo thuật toán BPE [2] hoặc SentencePiece). Mỗi token được ánh xạ thành một vector nhúng; các vector này được cập nhật qua nhiều lớp Transformer để tạo ra biểu diễn ngữ cảnh hóa. Chất lượng tokenizer ảnh hưởng trực tiếp đến khả năng xử lý tiếng Việt, đặc biệt với các từ ghép và dấu thanh.

2.2.3 Quá trình huấn luyện

Một mô hình ngôn ngữ lớn thường trải qua các giai đoạn:

1. **Tiền huấn luyện (pre-training):** huấn luyện mô hình dự đoán token tiếp theo trên khối lượng văn bản khổng lồ [3]. Giai đoạn này giúp mô hình học ngữ pháp, kiến thức phổ quát và khả năng suy luận ngôn ngữ.
2. **Tinh chỉnh có giám sát (instruction tuning/SFT):** tiếp tục huấn luyện trên các cặp hướng dẫn – đáp án để mô hình biết cách "trả lời" thay vì chỉ "hoàn thành văn bản" [4].
3. **Căn chỉnh theo phản hồi con người (RLHF) hoặc tối ưu theo sở thích (DPO):** điều chỉnh mô hình theo sở thích của con người về tính hữu ích, trung thực và an toàn [5, 6].

2.2.4 Sinh văn bản và nhắc lệnh

Khi suy luận, mô hình sinh token lần lượt theo một chiến lược giải mã. Nhiệt độ (temperature) điều chỉnh độ ngẫu nhiên; top-k và top-p (nucleus sampling) giới hạn tập token được chọn, giúp cân bằng giữa tính đa dạng và tính ổn định. Chất lượng đầu ra phụ thuộc rất lớn vào *nhắc lệnh* (prompt): kỹ thuật zero-shot, few-shot (đưa ví dụ) và chuỗi suy luận (Chain-of-Thought – CoT) [7] giúp định hướng mô hình giải quyết tác vụ.

2.3 Sinh tăng cường truy hồi (RAG)

2.3.1 Khái niệm và động lực

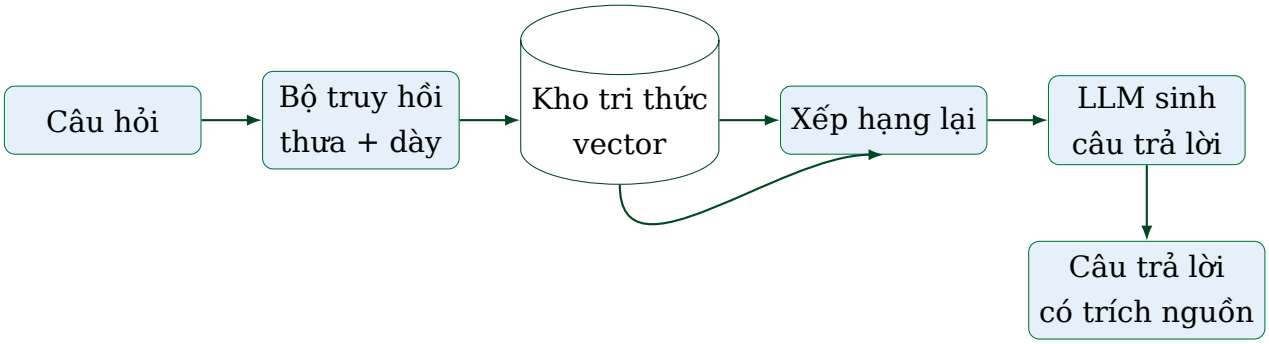
Sinh tăng cường truy hồi [8] là kỹ thuật kết hợp một bộ truy hồi (retriever) với một mô hình sinh (generator). Thay vì buộc mô hình phải "nhớ" toàn bộ tri thức trong tham số, RAG truy hồi các đoạn tài liệu liên quan từ kho tri thức ngoài tại thời điểm suy luận, rồi cung cấp chúng làm ngữ cảnh để mô hình sinh câu trả lời. Cách tiếp cận này mang lại ba lợi ích chính: (i) cập nhật tri thức mà không cần huấn luyện lại; (ii) giảm hiện tượng ảo giác nhờ ràng buộc vào bằng chứng; và (iii) cho phép trích dẫn nguồn, tăng tính kiểm chứng.

2.3.2 Kiến trúc tổng quát

Một hệ RAG điển hình gồm hai pha: *lập chỉ mục* (indexing) và *suy luận* (inference). Ở pha lập chỉ mục, tài liệu được chuẩn hóa, chia đoạn, nhúng thành vector và lưu vào cơ sở dữ liệu vector. Ở pha suy luận, câu hỏi của người dùng được nhúng, bộ truy hồi tìm các đoạn liên quan, chúng được xếp hạng lại và ghép thành ngữ cảnh, cuối cùng mô hình sinh câu trả lời.

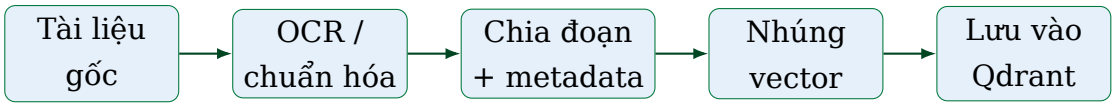
2.3.3 Chia đoạn và tiền xử lý tài liệu

Chất lượng của RAG phụ thuộc trước hết vào cách tài liệu được chia thành các *đoạn* (chunk). Đoạn quá lớn làm loãng ngữ cảnh và tăng chi phí; đoạn quá nhỏ làm mất mạch thông tin. Với tài liệu nghiệp vụ chứa nhiều bảng biểu và tiêu đề, chiến lược chia đoạn thường dùng là *nhận biết cấu trúc* (header-aware): cắt theo tiêu đề mục, giữ nguyên bảng, đặt độ dài tối đa



Hình 2.2: Kiến trúc tổng quát của một hệ thống RAG.

và độ chồng lấn (overlap) hợp lý để bảo toàn ngữ cảnh giữa các đoạn liền kề. Với tài liệu scan hoặc ảnh, cần bước nhận dạng ký tự quang học (OCR) trước khi chia đoạn.



Hình 2.3: Pipeline lập chỉ mục tài liệu trong hệ thống RAG.

2.3.4 Nhúng vector và cơ sở dữ liệu vector

Mô hình nhúng (embedding) ánh xạ đoạn văn bản thành một vector số thực trong không gian nhiều chiều, sao cho các đoạn có ngữ nghĩa gần nhau nằm gần nhau. Độ tương đồng thường được đo bằng cosine:

$$\mathrm{sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|}. \tag{2.2}$$

Cơ sở dữ liệu vector (vector database) lưu trữ và tìm kiếm láng giềng gần nhất trên hàng triệu vector một cách hiệu quả nhờ các thuật toán chỉ mục xấp xỉ [9]. Trong đề tài này, Qdrant [10] được sử dụng với khả năng lưu song song vector dày (dense) và vector thưa (sparse) trong cùng một collection.

2.3.5 Truy hồi thưa, truy hồi dày và truy hồi lai

Truy hồi thưa (sparse retrieval) biểu diễn văn bản bằng vector thưa dựa trên tần suất từ, tiêu biểu là BM25 [11]. Điểm BM25 giữa câu truy vấn q và tài liệu d được tính:

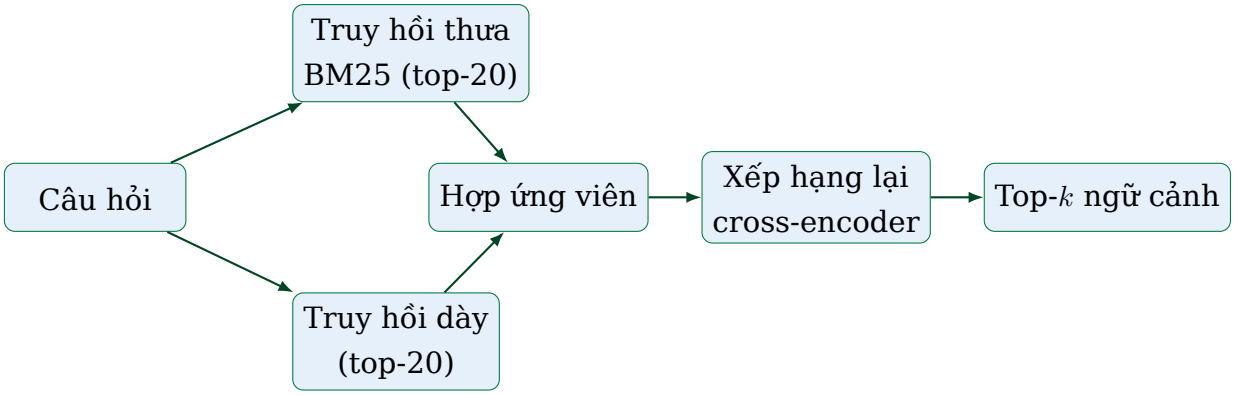
$$\text{BM25}(q,d) = \sum_{t \in q} \text{IDF}(t) \cdot \frac{f(t,d)\,(k_1+1)}{f(t,d) + k_1 \left(1 - b + b\,\frac{|d|}{\text{avgdl}}\right)}, \tag{2.3}$$

trong đó $f(t,d)$ là tần suất từ t trong d, $|d|$ là độ dài tài liệu, avgdl là độ dài trung bình, và k_1, b là các tham số điều chỉnh. BM25 mạnh ở việc khớp từ khóa chính xác, đặc biệt với số hiệu văn bản, mã dịch vụ hoặc thuật ngữ hiếm.

Truy hồi dày (dense retrieval) [12] sử dụng mô hình nhúng để biểu diễn câu hỏi và tài liệu trong cùng không gian ngữ nghĩa, nhờ đó bắt được các trường hợp diễn đạt đồng nghĩa mà BM25 bỏ sót. Hai phương pháp có ưu nhược điểm bổ trợ cho nhau. *Truy hồi lai* (hybrid retrieval) kết hợp cả hai bằng cách lấy hợp hoặc kết hợp điểm số, thường cho kết quả tốt hơn từng phương pháp riêng lẻ.

2.3.6 Xếp hạng lại

Các bộ truy hồi giai đoạn đầu (first-stage retrieval) thường nhanh nhưng kém chính xác do phải quét trên toàn kho. Bộ *xếp hạng lại* (reranker) tinh chỉnh thứ tự ứng viên bằng một mô hình mạnh hơn – thường là mô hình cross-encoder đọc đồng thời câu hỏi và đoạn văn để cho điểm tương quan. Quy trình điển hình: lấy một tập ứng viên lớn ở giai đoạn một (ví dụ top-20 mỗi nhánh), hợp chúng lại, rồi xếp hạng lại toàn bộ và giữ top-k nhỏ (ví dụ top-5) làm ngữ cảnh cho mô hình sinh.



Hình 2.4: Pipeline truy hồi lai kết hợp BM25, truy hồi dày và xếp hạng lại.

2.3.7 Các biến thể của RAG

Từ kiến trúc cơ bản, RAG có nhiều biến thể [13]. *Naive RAG* là dạng đơn giản nhất với truy hồi một lần. *Advanced RAG* bổ sung tiền xử lý truy vấn, hậu xử lý kết quả và xếp hạng lại. *Modular RAG* tổ chức thành các mô-đun linh hoạt có thể thay thế. Ngoài ra, *GraphRAG* khai thác đồ thị tri thức để truy hồi theo quan hệ giữa các thực thể, và *agentic RAG* cho phép tác tử quyết định truy hồi nhiều vòng, cải viết truy vấn hoặc gọi công cụ khác khi cần. Đề tài này áp dụng advanced/modular RAG với truy hồi lai và xếp hạng lại, đồng thời định hướng mở rộng lên agentic và GraphRAG trong tương lai.

2.4 Tinh chỉnh mô hình ngôn ngữ lớn (Fine-tuning)

2.4.1 Khái niệm và các mức độ

Tinh chỉnh (fine-tuning) là quá trình tiếp tục huấn luyện một mô hình đã được tiền huấn luyện trên một tập dữ liệu chuyên biệt, nhằm điều chỉnh mô hình phù hợp với miền hoặc tác vụ cụ thể. Có thể chia thành hai nhóm:

- **Tinh chỉnh toàn bộ (full fine-tuning):** cập nhật toàn bộ tham số mô hình. Hiệu quả cao nhưng đòi hỏi tài nguyên tính toán và bộ nhớ rất lớn, đồng thời cần lưu toàn bộ bản sao mô hình cho mỗi tác vụ.
- **Tinh chỉnh hiệu quả tham số (PEFT):** chỉ cập nhật một phần nhỏ tham số, giữ nguyên phần lớn mô hình gốc. Tiêu biểu là LoRA và QLoRA.

2.4.2 Tinh chỉnh có giám sát và căn chỉnh

Tinh chỉnh có giám sát (Supervised Fine-Tuning – SFT) huấn luyện mô hình trên các cặp hướng dẫn – đáp án chất lượng cao. Để mô hình trả lời đúng "giọng" nghiệp vụ, dữ liệu SFT cần được thiết kế cẩn thận cả về nội dung lẫn định dạng. Sau SFT, có thể áp dụng RLHF hoặc DPO [6] để căn chỉnh theo sở thích con người, giúp câu trả lời hữu ích và an toàn hơn.

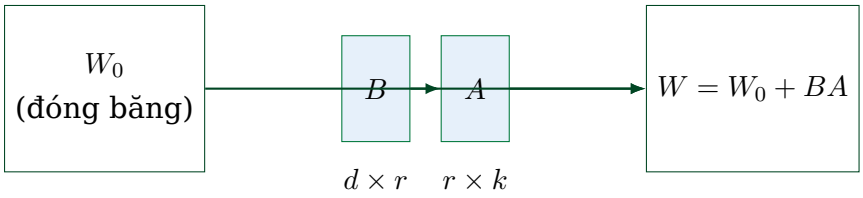
2.4.3 LoRA

LoRA (Low-Rank Adaptation) [14] giả định rằng thay đổi tham số khi thích ứng một tác vụ có "hạng thấp" (low intrinsic rank). Thay vì cập nhật toàn

bộ ma trận trọng số $W_0 \in \mathbb{R}^{d\times k}$, LoRA giữ nguyên W_0 và thêm một phần hiệu chỉnh phân rã thành tích hai ma trận hạng thấp:

$$W = W_0 + \Delta W = W_0 + BA, \qquad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},\ r \ll \min(d,k). \tag{2.4}$$

Ma trận A được khởi tạo ngẫu nhiên và B được khởi tạo bằng 0 để lúc bắt đầu $\Delta W = 0$, bảo toàn hành vi mô hình gốc. Số tham số huấn luyện giảm từ $d \times k$ xuống $r(d+k)$, thường chỉ còn dưới 1% tổng tham số. Hệ số α và hạng r quyết định độ lớn của cập nhật; giá trị hiệu chỉnh thường được nhân với α/r.



Hình 2.5: Minh họa LoRA: giữ nguyên W_0 và thêm cập nhật hạng thấp BA.

2.4.4 QLoRA

QLoRA [15] mở rộng LoRA bằng cách lượng tử hóa mô hình gốc xuống 4 bit (định dạng NF4), áp dụng lượng tử hóa kép (double quantization) và tối ưu hóa phân trang (paged optimizers). Nhờ đó có thể tinh chỉnh các mô hình lớn trên phần cứng khiêm tốn hơn đáng kể so với full fine-tuning, với mức suy giảm chất lượng nhỏ.

2.4.5 Khi nào nên dùng fine-tuning

Fine-tuning phù hợp khi cần điều chỉnh *hành vi* của mô hình (phong cách, định dạng, quy trình nghiệp vụ ổn định) hoặc khi tri thức miền mang tính ổn định và khó mô tả bằng ngữ cảnh truy hồi. Ngược lại, khi tri thức thay đổi thường xuyên hoặc cần trích dẫn nguồn, RAG là lựa chọn phù hợp hơn.

2.5 So sánh RAG và fine-tuning, kiến trúc lai

RAG và fine-tuning giải quyết hai lớp vấn đề khác nhau và có thể bổ trợ cho nhau. Bảng 2.1 tóm tắt sự so sánh.

Bảng 2.1: So sánh RAG và fine-tuning theo các tiêu chí triển khai.

Tiêu chí	**RAG**	**Fine-tuning**
Nguồn tri thức	Kho tài liệu ngoài, truy hồi động	Tham số mô hình, cố định sau huấn luyện
Cập nhật tri thức	Chỉ cần cập nhật chỉ mục	Cần huấn luyện lại
Khả năng trích nguồn	Có (dựa trên đoạn truy hồi)	Hạn chế
Chi phí huấn luyện	Thấp (chủ yếu lập chỉ mục)	Cao hơn (SFT/LoRA)
Chi phí suy luận	Cao hơn (thêm truy hồi)	Thấp hơn (chỉ sinh)
Điều chỉnh phong cách/định dạng	Yếu	Mạnh
Giảm ảo giác	Tốt nếu truy hồi đúng	Trung bình
Phù hợp nhất với	Tri thức động, tra cứu	Hành vi miền ổn định

Từ so sánh trên, đề tài đề xuất *kiến trúc lai* kết hợp cả hai: sử dụng RAG làm kênh cung cấp tri thức động và bằng chứng, đồng thời dùng mô hình đã tinh chỉnh để sinh câu trả lời đúng phong cách, đúng định dạng nghiệp vụ và xử lý các tình huống ổn định. Một bộ định tuyến (router) quyết định khi nào chỉ cần RAG, khi nào dùng mô hình tinh chỉnh, và khi nào kết hợp. Chi tiết kiến trúc được trình bày ở chương 3.

2.6 Các thước đo đánh giá

Đánh giá một hệ RAG cần tách thành hai khâu: chất lượng truy hồi và chất lượng sinh.

2.6.1 Thước đo truy hồi

- **Recall@k:** tỉ lệ các tài liệu/đoạn liên quan được tìm thấy trong top-k. Đây là thước đo quan trọng nhất vì nếu tài liệu đúng không nằm trong ngữ cảnh thì mô hình không thể trả lời đúng.
- **Precision@k:** tỉ lệ đoạn liên quan trong top-k.
- **MRR (Mean Reciprocal Rank):** nghịch đảo thứ hạng của đoạn liên quan đầu tiên, trung bình trên các truy vấn. MRR cao nghĩa là đoạn đúng xuất hiện sớm.

- **nDCG:** thước đo có trọng số theo vị trí, phù hợp khi đánh giá chất lượng xếp hạng với mức độ liên quan khác nhau.

2.6.2 Thước đo sinh văn bản

Bộ thước đo RAGAS [16] đánh giá hệ RAG không cần đáp án tham chiếu đầy đủ:

- **Faithfulness (độ trung thực):** mức độ câu trả lời được hỗ trợ bởi ngữ cảnh truy hồi, phản ánh mức độ ảo giác.
- **Answer Relevancy (độ liên quan câu trả lời):** mức độ câu trả lời đúng trọng tâm câu hỏi.
- **Context Precision:** tỉ lệ đoạn ngữ cảnh thực sự hữu ích.
- **Context Recall:** mức độ ngữ cảnh bao phủ đáp án tham chiếu.

Ngoài ra, *LLM-as-judge* sử dụng một mô hình ngôn ngữ mạnh để cho điểm câu trả lời theo thang điểm (ví dụ 0–10) dựa trên đáp án chuẩn, là phương pháp linh hoạt và tiết kiệm cho miền hẹp. Các thước đo truyền thống như BLEU và ROUGE có thể dùng bổ sung nhưng không phản ánh tốt tính đúng đắn ngữ nghĩa trong hỏi đáp mở.

2.7 Nền tảng triển khai

2.7.1 Phục vụ suy luận với vLLM

vLLM [17, 18] là thư viện phục vụ suy luận LLM hiệu năng cao, nổi bật với cơ chế PagedAttention quản lý bộ nhớ KV-cache theo trang, cho phép tăng thông lượng đáng kể nhờ xử lý theo lô liên tục (continuous batching). Kết hợp với lượng tử hóa FP8, vLLM cho phép phục vụ các mô hình hàng chục tỷ tham số trên GPU với chi phí hợp lý.

2.7.2 Lượng tử hóa FP8

FP8 là định dạng số dấu phẩy động 8 bit, giảm một nửa dung lượng bộ nhớ so với FP16 và tăng tốc tính toán trên phần cứng hỗ trợ, với mức suy giảm chất lượng thường nhỏ. Đây là lựa chọn phổ biến để phục vụ mô hình lớn trên hạ tầng giới hạn.

2.7.3 Giao thức MCP và A2A

Model Context Protocol (MCP) [19] chuẩn hóa cách mô hình truy cập công cụ và nguồn dữ liệu, giúp tách biệt logic công cụ khỏi tác tử. **Agent-to-Agent (A2A)** [20] chuẩn hóa giao tiếp giữa các tác tử, cho phép một tác tử điều phối gọi tác tử chuyên biệt và nhận kết quả. Hai giao thức này tạo nên nền tảng cho kiến trúc đa tác tử của đề tài.

2.7.4 Quan sát hệ thống và quản lý prompt

OpenTelemetry (OTel) [21] cung cấp chuẩn thu thập vết (trace), chỉ số (metric) và log; dữ liệu được đẩy tới các nền tảng như Langfuse [22] hoặc Grafana Tempo để giám sát luồng suy luận, độ trễ và lượng token. MLflow Prompt Registry [23] cho phép quản lý phiên bản prompt tập trung, giúp tách cấu hình khỏi mã nguồn và kiểm soát thay đổi prompt theo môi trường (ví dụ nhãn `@production`).

Kết chương

Chương này đã hệ thống hóa nền tảng lý thuyết về chatbot, LLM, RAG, fine-tuning, kiến trúc lai, thước đo đánh giá và nền tảng triển khai. Đây là cơ sở để chương tiếp theo phân tích bài toán cụ thể của VNPost và thiết kế kiến trúc hệ thống đề xuất.

Chương 3

Kiến trúc hệ thống đề xuất

Trên nền tảng lý thuyết đã trình bày ở chương 2, chương này phân tích bài toán cụ thể của VNPost và đề xuất kiến trúc trợ lý ảo. Mục 3.1 làm rõ đặc thù bài toán; mục 3.2 xác định yêu cầu; mục 3.3 trình bày kiến trúc đa tác tử; mục 3.4 và mục 3.5 mô tả pipeline RAG và pipeline fine-tuning; mục 3.6 đề xuất kiến trúc lai; và mục 3.7 trình bày hạ tầng và bảo mật.

3.1 Đặc thù bài toán tại VNPost

3.1.1 Đặc điểm dữ liệu nội bộ

Dữ liệu nội bộ của VNPost có một số đặc điểm ảnh hưởng trực tiếp đến thiết kế hệ thống:

- **Đa dạng định dạng:** tài liệu tồn tại dưới dạng văn bản số (docx, pdf, txt) và cả bản scan. Điều này đòi hỏi bước nhận dạng ký tự quang học và chuẩn hóa về một định dạng thống nhất trước khi lập chỉ mục.
- **Cấu trúc phức tạp:** nhiều văn bản chứa bảng biểu (biểu phí, thời gian toàn trình, bảng phân loại hàng hóa), tiêu đề nhiều cấp và số hiệu văn bản. Việc chia đoạn phải bảo toàn bảng và ngữ cảnh tiêu đề.
- **Ngôn ngữ chuyên ngành:** nhiều thuật ngữ, từ viết tắt và số hiệu đặc thù (ví dụ số quyết định, mã dịch vụ), đòi hỏi cấu hình truy hồi thưa phù hợp với tiếng Việt.
- **Tính động:** biểu phí và quy định thay đổi theo thời gian, nên tri thức cần được cập nhật mà không phải huấn luyện lại mô hình.
- **Tính bảo mật:** tài liệu nội bộ và dữ liệu khách hàng không được phép rời khỏi hạ tầng của Tổng công ty.

3.1.2 Các nhóm nghiệp vụ

Hệ thống phục vụ ba nhóm nghiệp vụ chính: (i) hỏi đáp trên tài liệu văn thư và sản phẩm – dịch vụ; (ii) tra cứu tình trạng bưu gửi; và (iii) tra cứu thông tin bưu cục. Ngoài ra còn các nghiệp vụ mở rộng như tra cứu chất lượng phát và tra cứu tài chính – kế toán.

3.2 Yêu cầu chức năng và phi chức năng

3.2.1 Yêu cầu chức năng

- Trả lời câu hỏi tự nhiên dựa trên tài liệu nội bộ, có trích dẫn nguồn.
- Ngữ cảnh hóa câu trả lời theo lịch sử hội thoại nhiều lượt.
- Tra cứu tình trạng bưu gửi và thông tin bưu cục qua kết nối hệ thống nghiệp vụ.
- Định tuyến yêu cầu đến tác tử chuyên biệt phù hợp và hợp nhất kết quả.
- Hỗ trợ tạo phiếu yêu cầu (ticket) khi cần chuyển sang hỗ trợ thủ công.
- Gợi ý câu hỏi mở đầu phù hợp với nhu cầu người dùng.

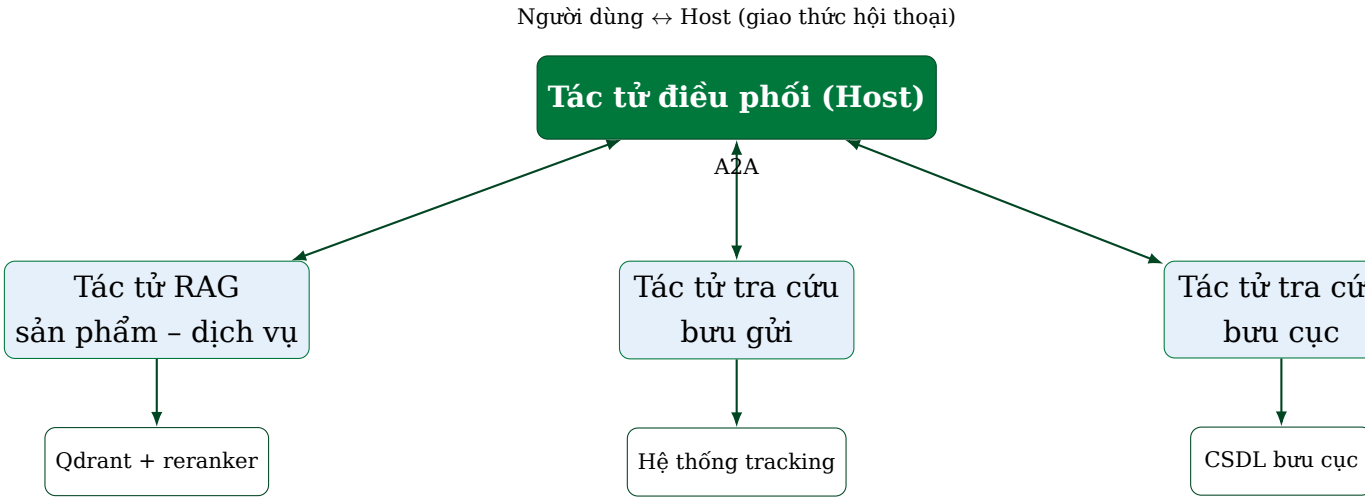
3.2.2 Yêu cầu phi chức năng

- **Chính xác và có căn cứ:** câu trả lời phải bám sát tài liệu, hạn chế tối đa ảo giác.
- **Bảo mật:** toàn bộ mô hình và dữ liệu vận hành cục bộ, không gửi ra ngoài.
- **Độ trễ chấp nhận được:** phản hồi trong vài giây cho câu hỏi thông thường.
- **Khả năng mở rộng:** dễ thêm tác tử, kho tài liệu và mô hình mới.
- **Quan sát được:** có vết, log và chỉ số để giám sát và cải tiến.
- **Kiểm soát truy cập:** phân quyền theo vai trò đối với dữ liệu nhạy cảm.

3.3 Kiến trúc tổng thể đa tác tử

Đề tài đề xuất kiến trúc *đa tác tử* gồm một tác tử điều phối trung tâm (host orchestrator) và các tác tử chuyên biệt. Tác tử điều phối chịu trách nhiệm

hiểu yêu cầu, duy trì ngữ cảnh hội thoại, quyết định định tuyến và hợp nhất câu trả lời. Các tác tử chuyên biệt đảm nhận từng miền nghiệp vụ hẹp và được gọi qua giao thức A2A; mỗi tác tử truy cập công cụ của mình qua giao thức MCP.



Hình 3.1: Kiến trúc đa tác tử: host điều phối các tác tử chuyên biệt qua A2A.

Ưu điểm của kiến trúc này là tách biệt trách nhiệm rõ ràng: mỗi tác tử có prompt, công cụ và kho dữ liệu riêng, dễ kiểm thử và nâng cấp độc lập. Tác tử điều phối chỉ cần biết "khi nào gọi ai", nhờ đó giảm tải nhận thức và tăng độ ổn định.

3.4 Pipeline RAG chi tiết

3.4.1 Pha lập chỉ mục

Pha lập chỉ mục biến tài liệu thô thành các đoạn vector trong Qdrant qua các bước:

1. **Thu thập và chuẩn hóa:** tài liệu được thu thập, với các bản scan được xử lý OCR bằng mô hình nhận dạng (ví dụ `olmocr-2-7b` hoặc `lightonocr2-1b`).
2. **Chuyển sang Markdown:** tài liệu được chuyển thành văn bản có cấu trúc để bảo toàn tiêu đề và bảng.
3. **Trích xuất metadata:** mỗi tài liệu được gắn metadata như tiêu đề, số hiệu văn bản, ngày ban hành và tóm tắt do mô hình ngôn ngữ sinh ra.

4. **Chia đoạn:** văn bản được chia thành các đoạn nhận biết cấu trúc, với độ dài tối đa và độ chồng lấn hợp lý, bảo toàn bảng biểu.
5. **Nhúng và lưu trữ:** mỗi đoạn được nhúng thành vector bằng mô hình nhúng và lưu vào Qdrant, cùng vector thưa cho BM25.

3.4.2 Pha truy hồi và sinh

Khi có câu hỏi, hệ thống thực hiện:

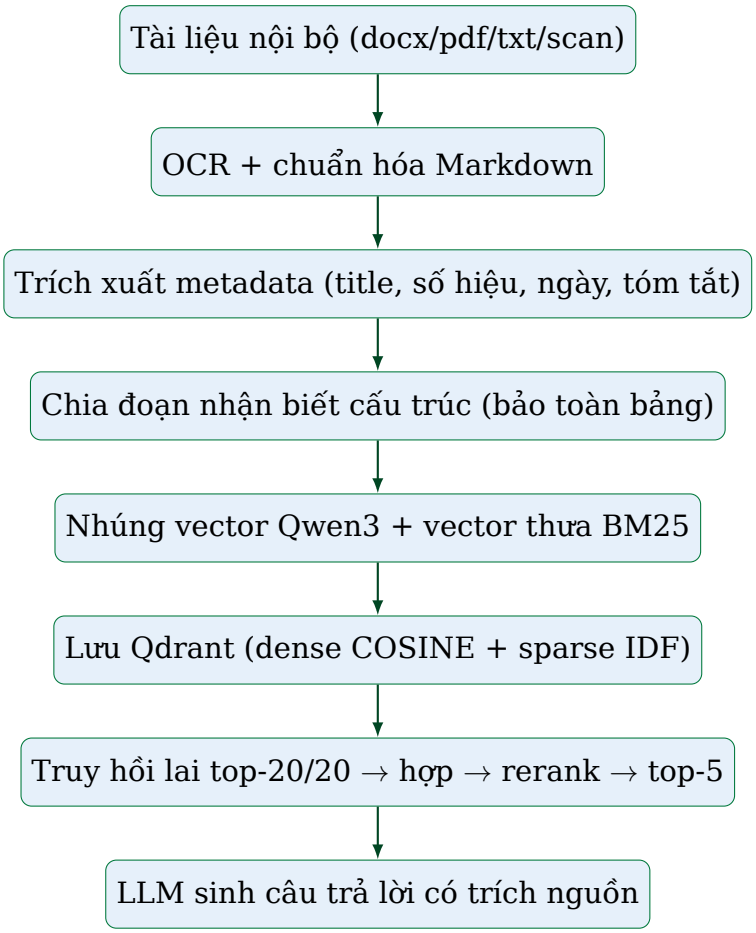
1. **Nhúng câu hỏi** bằng cùng mô hình nhúng đã dùng khi lập chỉ mục.
2. **Truy hồi lai:** chạy song song truy hồi thưa BM25 và truy hồi dày, mỗi nhánh lấy top-k_1 ứng viên (ví dụ 20).
3. **Hợp ứng viên:** gộp kết quả hai nhánh và loại trùng.
4. **Xếp hạng lại:** dùng cross-encoder xếp hạng lại toàn bộ ứng viên và giữ top-k_2 (ví dụ 5) làm ngữ cảnh.
5. **Sinh câu trả lời:** mô hình ngôn ngữ nhận câu hỏi, ngữ cảnh truy hồi và lịch sử hội thoại để sinh câu trả lời có trích nguồn.

3.4.3 Tham số hóa và cấu hình

Các tham số chính gồm số ứng viên mỗi nhánh truy hồi (k_1), số đoạn sau xếp hạng lại (k_2) và ngưỡng điểm tối thiểu để loại bỏ ngữ cảnh không liên quan. Cấu hình thực tế được trình bày ở chương 4. Cơ chế ngưỡng điểm giúp hệ thống từ chối trả lời khi không tìm thấy bằng chứng phù hợp, thay vì "bịa" câu trả lời.

3.5 Pipeline fine-tuning đề xuất

Vì codebase hiện tại của VNPost chưa có pipeline fine-tuning, phần này trình bày *thiết kế đề xuất*. Mục tiêu của fine-tuning trong bối cảnh này không phải là nạp tri thức (đã do RAG đảm nhiệm) mà là điều chỉnh hành vi: phong cách trả lời, định dạng nghiệp vụ, cách xử lý các tình huống lặp và mức độ tuân thủ quy tắc.



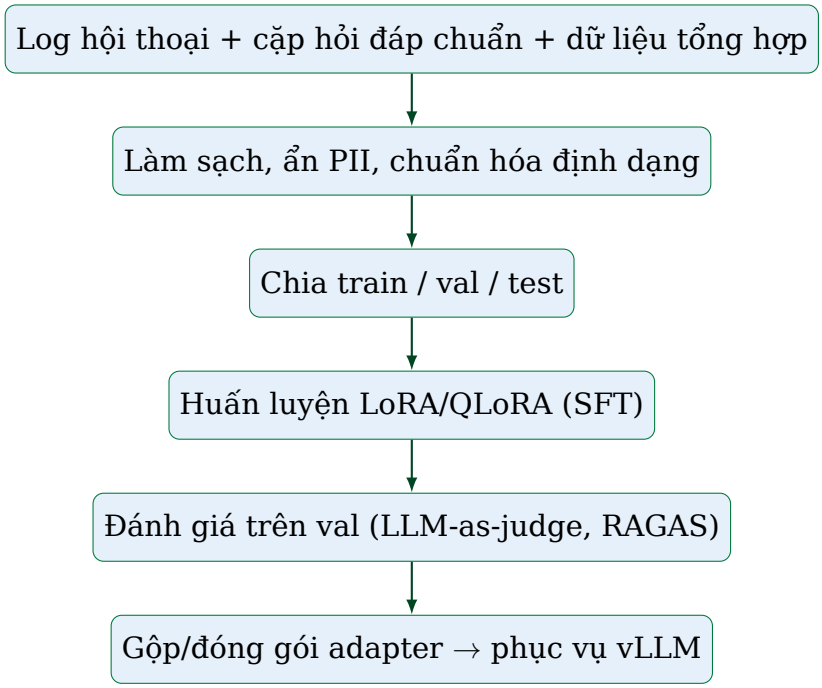
Hình 3.2: Pipeline RAG đầy đủ từ lập chỉ mục đến sinh câu trả lời.

3.5.1 Thu thập và chuẩn bị dữ liệu

Dữ liệu huấn luyện được tổng hợp từ ba nguồn: (i) log hội thoại thực tế giữa người dùng và hệ thống, sau khi lọc và ẩn thông tin định danh cá nhân (PII); (ii) các cặp hỏi – đáp chuẩn do chuyên gia nghiệp vụ xây dựng; và (iii) dữ liệu tổng hợp do mô hình mạnh sinh ra có kiểm duyệt. Dữ liệu được định dạng theo mẫu hội thoại (instruction – response) và chia thành tập huấn luyện, tập kiểm định và tập kiểm thử.

3.5.2 Cấu hình LoRA/QLoRA

Đề xuất sử dụng LoRA hoặc QLoRA với hạng $r = 16$, hệ số $\alpha = 32$, dropout nhỏ, và áp dụng lên các ma trận chiếu trong khối attention và feed-forward (query, key, value, output, gate, up, down). Mô hình gốc được giữ ở định dạng lượng tử hóa 4 bit khi dùng QLoRA để tiết kiệm bộ nhớ. Sau huấn luyện, adapter có thể được gộp (merge) vào mô hình gốc hoặc phục vụ như một adapter riêng trong vLLM.



Hình 3.3: Pipeline fine-tuning đề xuất cho trợ lý ảo VNPost.

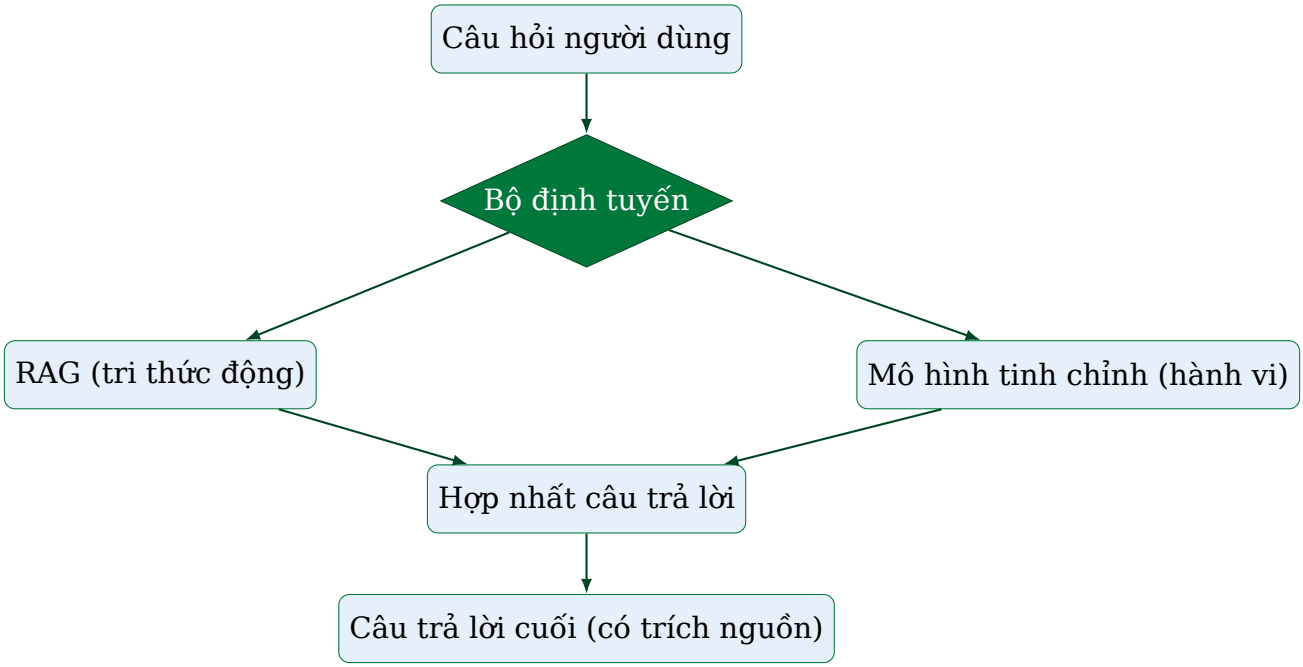
Ghi chú minh bạch: pipeline fine-tuning trong báo cáo là thiết kế đề xuất*; các kết quả liên quan ở chương 5 (nếu có) được ghi rõ là kết quả minh họa, không phải kết quả huấn luyện thật trên hạ tầng VNPost.*

3.6 Kiến trúc lai RAG + Fine-tuning

Kiến trúc lai sử dụng một bộ định tuyến để quyết định chiến lược trả lời:

- **Chỉ RAG:** với câu hỏi cần tri thức động hoặc cần trích dẫn nguồn (biểu phí, quy định, số hiệu văn bản). Đây là chế độ mặc định cho phần lớn truy vấn.
- **Chỉ mô hình tinh chỉnh:** với câu hỏi về phong cách, định dạng, hướng dẫn quy trình ổn định, hoặc khi cần câu trả lời ngắn gọn theo mẫu nghiệp vụ.
- **Kết hợp:** mô hình tinh chỉnh sinh khung câu trả lời theo định dạng nghiệp vụ, sau đó RAG bổ sung bằng chứng và số liệu cụ thể; mô hình hợp nhất tạo câu trả lời cuối.

Bộ định tuyến có thể dựa trên phân loại ý định nhẹ, hoặc để chính tác tử điều phối quyết định dựa trên prompt. Khi RAG không tìm thấy bằng chứng đủ tin cậy, hệ thống chuyển sang thông báo thiếu thông tin hoặc tạo ticket, tránh sinh câu trả lời không căn cứ.



Hình 3.4: Kiến trúc lai: bộ định tuyến chọn RAG, mô hình tinh chỉnh hoặc kết hợp.

3.7 Hạ tầng và bảo mật

3.7.1 Hạ tầng phục vụ

Toàn bộ hệ thống được triển khai trên Kubernetes để bảo đảm khả năng mở rộng và ổn định. Các mô hình được phục vụ cục bộ bằng vLLM với lượng tử hóa FP8. Các mô hình chính gồm: mô hình sinh ngôn ngữ (ví dụ họ Qwen với các biến thể 27B–35B), mô hình nhúng văn bản (ví dụ Qwen3-Embedding-8B), mô hình xếp hạng lại (Qwen3-Reranker-8B) và mô hình OCR. Qdrant đảm nhiệm lưu trữ vector.

3.7.2 Bảo mật dữ liệu

Yêu cầu bảo mật được thực thi ở nhiều lớp: (i) mô hình chạy cục bộ, dữ liệu không rời hạ tầng; (ii) kiểm soát truy cập theo vai trò (RBAC) đối với dữ liệu nhạy cảm; (iii) ẩn PII trong log trước khi dùng cho phân tích hoặc fine-tuning; và (iv) phân quyền ở tầng dữ liệu, bảo đảm người dùng chỉ truy cập được phạm vi cho phép.

Kết chương

Chương này đã phân tích bài toán VNPost, xác định yêu cầu và đề xuất kiến trúc đa tác tử kết hợp RAG lai với fine-tuning theo mô hình lai. Chương tiếp theo mô tả việc triển khai thực nghiệm các thành phần này cùng các tham số cụ thể.

Chương 4

Triển khai thực nghiệm

Chương này trình bày việc triển khai hệ thống theo kiến trúc đã đề xuất ở chương 3. Mục 4.1 mô tả môi trường và công cụ; mục 4.2 mô tả dữ liệu; mục 4.3 trình bày cấu hình RAG; mục 4.4 trình bày thiết kế fine-tuning; mục 4.5 mô tả triển khai đa tác tử; mục 4.6 trình bày hệ thống quan sát và quản lý prompt; và mục 4.7 tổng kết khó khăn cùng giải pháp.

4.1 Môi trường và công cụ

Hệ thống được triển khai theo mô hình microservice trên nền Kubernetes, đóng gói bằng Docker. Bảng 4.1 liệt kê các công cụ chính.

Bảng 4.1: Các công cụ và thành phần chính của hệ thống.

Thành phần	Vai trò
vLLM	Phục vụ suy luận LLM, embedding, reranker và OCR với FP8
Qdrant	Cơ sở dữ liệu vector, lưu vector dày và thưa
Kubernetes	Điều phối container, mở rộng và ổn định dịch vụ
Docker Compose	Triển khai cục bộ phục vụ phát triển và thử nghiệm
MLflow	Quản lý phiên bản prompt và gateway
Langfuse / Grafana Tempo	Thu thập và trực quan hóa vết suy luận
OpenTelemetry	Chuẩn thu thập trace, metric, log
Airflow	Lập lịch thu thập và cập nhật dữ liệu định kỳ
PostgreSQL	Lưu trữ dữ liệu nghiệp vụ (bưu cục, tracking)

4.2 Dữ liệu

4.2.1 Các kho tài liệu

Đề tài sử dụng ba kho tài liệu đại diện cho các miền nghiệp vụ khác nhau, tóm tắt ở bảng 4.2.

Bảng 4.2: Thống kê các kho tài liệu sử dụng trong thực nghiệm.

Kho tài liệu	Số tài liệu	Nội dung tiêu biểu
Văn thư nội bộ	17	Quyết định, công văn, quy trình nghiệp vụ
Sản phẩm – dịch vụ	119	Biểu phí, quy định hàng hóa, bồi thường, thời gian toàn trình
Chuyển phát nhanh EMS	≈ 30	Biểu phí EMS, quy định hàng hóa đặc biệt, bồi thường

Kho tài liệu sản phẩm – dịch vụ gồm 114 tệp văn bản, 3 tệp PDF và 2 tệp docx; sau khi chuẩn hóa, mỗi tài liệu được sinh thêm một tệp Markdown và gắn metadata (tiêu đề, số hiệu, ngày, tóm tắt). Kho văn thư gồm các quyết định và công văn về cước phí, thời gian toàn trình, hàng hóa cấm gửi và chính sách bồi thường.

4.2.2 Bộ đánh giá

Bộ đánh giá cho miền EMS gồm 99 cặp câu hỏi – đáp án tham chiếu, được trích từ một bảng gồm hơn 400 dòng dữ liệu thô và lọc lại còn 99 cặp sử dụng được. Bộ này được dùng cho cả đánh giá truy hồi lẫn đánh giá sinh văn bản. Ngoài ra, một bộ mẫu nhỏ (6 câu hỏi) được dùng để đánh giá truy hồi chi tiết theo từng nhánh (BM25, dense) và một bộ mẫu 3 câu cho đánh giá agent bằng LLM-as-judge.

4.2.3 Tiền xử lý

Quy trình tiền xử lý gồm: OCR cho bản scan; chuyển đổi sang Markdown; trích xuất metadata; chia đoạn nhận biết cấu trúc; và sinh file băm (hash) để theo dõi thay đổi tài liệu. Đối với tiếng Việt, cấu hình truy hồi thưa được

điều chỉnh: tắt stemming và loại bỏ danh sách từ dừng, vì stemming tiếng Việt kém hiệu quả với thuật ngữ chuyên ngành và số hiệu văn bản.

4.3 Cài đặt RAG

4.3.1 Chia đoạn và nhúng

Văn bản được chia thành các đoạn với độ dài tối đa khoảng 1000 ký tự và độ chồng lấn bảo toàn ngữ cảnh. Bộ chia đoạn ưu tiên ranh giới theo tiêu đề và giữ nguyên bảng. Mỗi đoạn được nhúng bằng mô hình Qwen3-Embedding với vector 4096 chiều; song song đó, vector thưa cho BM25 được tạo với chỉ số IDF.

4.3.2 Cấu hình truy hồi

Bảng 4.3 trình bày các tham số truy hồi chính. Ở nhánh sản phẩm – dịch vụ của hệ thống đa tác tử, số ứng viên BM25 là 10 và số ứng viên sau xếp hạng lại là 10; ở cấu hình mẫu (template) dùng cho đánh giá truy hồi, các giá trị tương ứng là 20/20/5.

Bảng 4.3: Cấu hình tham số truy hồi RAG.

Tham số	**Cấu hình mẫu**	**Nhánh SPDV**
Số ứng viên dense (k_1^{dense})	20	20
Số ứng viên BM25 (k_1^{bm25})	20	10
Số đoạn sau rerank (k_2)	5	10
Ngưỡng điểm rerank	0,0	0,0
Số chiều embedding	4096	4096
Độ dài đoạn tối đa	≈ 1000	≈ 1000

4.3.3 Nhúng câu hỏi và prompt

Câu hỏi được nhúng với chỉ dẫn (instruction) phù hợp cho truy hồi. Prompt hệ thống của tác tử RAG được quản lý tập trung qua MLflow Prompt Registry (ví dụ tham chiếu `prompts:/tct-rag-agent@production`), cho phép cập nhật mà không cần triển khai lại mã. Prompt quy định rõ: chỉ trả lời dựa trên ngữ cảnh truy hồi, trích nguồn, và từ chối khi thiếu thông tin.

4.4 Thiết kế fine-tuning

Như đã nêu, đây là phần *thiết kế đề xuất*. Bảng 4.4 trình bày cấu hình LoRA/QLoRA đề xuất.

Bảng 4.4: Cấu hình LoRA/QLoRA đề xuất cho fine-tuning.

Tham số	**Giá trị đề xuất**
Phương pháp	LoRA / QLoRA (4-bit NF4)
Hạng r	16
Hệ số α	32
Dropout	0,05
Module áp dụng	q, k, v, o, gate, up, down
Tốc độ học	1×10^{-4} đến 2×10^{-4}
Số epoch	2–3
Độ dài ngữ cảnh	4096 token
Chiến lược	SFT, có thể bổ sung DPO

Dữ liệu huấn luyện dự kiến gồm log hội thoại đã ẩn PII, cặp hỏi – đáp chuẩn do chuyên gia xây dựng, và dữ liệu tổng hợp có kiểm duyệt. Quy trình: làm sạch $\rightarrow$ định dạng $\rightarrow$ chia tập $\rightarrow$ huấn luyện SFT $\rightarrow$ đánh giá trên tập kiểm định $\rightarrow$ đóng gói adapter để phục vụ bằng vLLM.

4.5 Triển khai đa tác tử

4.5.1 Tác tử điều phối

Tác tử điều phối (host) tiếp nhận yêu cầu, duy trì ngữ cảnh hội thoại và quyết định định tuyến. Prompt của host quy định danh sách tác tử được phép gọi, tiêu chí định tuyến và cơ chế hợp nhất kết quả. Host cũng hỗ trợ tạo ticket khi cần chuyển sang hỗ trợ thủ công, với phân loại ticket theo nhóm nghiệp vụ (tư vấn, hỗ trợ ứng dụng, cước phí, đối soát thanh toán, hỗ trợ kỹ thuật).

4.5.2 Các tác tử chuyên biệt và công cụ

Các tác tử chuyên biệt giao tiếp qua A2A và truy cập công cụ qua MCP. Ví dụ, tác tử tra cứu bưu gửi cung cấp công cụ tra cứu theo SOAP và theo API

nội bộ, cùng công cụ phân tích điểm nghẽn (bottleneck). Tác tử tra cứu bưu cục truy vấn cơ sở dữ liệu PostgreSQL có tìm kiếm mờ (fuzzy search) để xử lý sai chính tả. Tác tử RAG sản phẩm – dịch vụ dùng Qdrant và reranker như mô tả.

4.5.3 Quy tắc định tuyến

Với miền EMS, hệ thống sử dụng một bộ khoảng 26 quy tắc chuyển tác tử, được nhóm theo các chủ đề: yêu cầu trực tiếp, khiếu nại/bồi thường, phản hồi, tác vụ vận hành, nghiệp vụ/hợp đồng, khách hàng VIP, an ninh/pháp lý, độ tin cậy thấp và chuyển cấp. Các quy tắc được lưu dưới dạng JSON có thể đọc bằng máy, bao gồm thông tin cần thu thập và chính sách theo giờ hành chính, giúp việc định tuyến nhất quán và dễ bảo trì.

4.6 Hệ thống quan sát và quản lý prompt

Mọi tác tử đều phát vết theo chuẩn OpenTelemetry tới một bộ thu (collector), sau đó phân phối tới Grafana Tempo và Langfuse. Vết ghi lại luồng gọi công cụ, mô hình được dùng, lượng token, thời gian tới token đầu tiên và độ trễ tổng. Thông tin phiên và người dùng được truyền qua baggage để liên kết các vết trong cùng một hội thoại.

Prompt được quản lý tập trung qua MLflow Prompt Registry. Mỗi tác tử tham chiếu một prompt theo tên và nhãn (ví dụ `@production`), nhờ đó có thể cập nhật prompt cho tất cả tác tử mà không cần sửa mã hay triển khai lại. Cơ chế này tách cấu hình khỏi logic và hỗ trợ kiểm soát thay đổi.

4.7 Khó khăn và giải pháp

Kết chương

Chương này đã mô tả môi trường, dữ liệu, cấu hình RAG, thiết kế fine-tuning, triển khai đa tác tử và hệ thống quan sát. Chương tiếp theo trình bày kết quả thực nghiệm và đánh giá.

Bảng 4.5: Khó khăn gặp phải và giải pháp áp dụng.

Khó khăn	**Giải pháp**
Stemming tiếng Việt kém hiệu quả	Tắt stemming, loại bỏ từ dừng trong BM25
Bảng biểu bị cắt vụn khi chia đoạn	Chia đoạn nhận biết cấu trúc, bảo toàn bảng
Tài liệu scan chất lượng thấp	Tiền xử lý OCR bằng mô hình nhận dạng chuyên dụng
Reranker làm giảm recall top-k nhỏ	Phân tích lỗi, điều chỉnh k và ngưỡng
Chi phí GPU cho mô hình lớn	Lượng tử hóa FP8, phục vụ theo lô với vLLM
Dữ liệu nhạy cảm	Chạy cục bộ, ẩn PII, RBAC theo vai trò
Prompt phân tán, khó kiểm soát	MLflow Prompt Registry tập trung

Chương 5

Kết quả và đánh giá

Chương này trình bày kết quả thực nghiệm của hệ thống. Mục 5.1 mô tả phương pháp đánh giá; mục 5.2 trình bày kết quả truy hồi; mục 5.3 trình bày kết quả sinh văn bản; mục 5.4 so sánh các hướng tiếp cận; mục 5.5 trình bày hiệu năng hệ thống; mục 5.6 nêu case study định tính; mục 5.7 ước lượng hiệu quả kinh tế – xã hội; và mục 5.8 thảo luận.

5.1 Phương pháp đánh giá

Đề tài đánh giá hệ thống theo ba lớp: (i) đánh giá truy hồi; (ii) đánh giá sinh văn bản; và (iii) đánh giá hiệu năng hệ thống.

Đánh giá truy hồi được thực hiện bằng một quy trình tái lập chính xác đường đi sản xuất: với mỗi câu hỏi, hệ thống chạy truy hồi thưa BM25 và truy hồi dày, lấy hợp ứng viên, xếp hạng lại, rồi so sánh tập kết quả với đáp án tham chiếu. Các thước đo gồm Recall@k cho từng nhánh, Recall sau hợp, Recall@k sau xếp hạng lại và MRR. Quy trình còn phân tách lỗi thành hai loại: lỗi *RECALL* (đoạn đúng không được truy hồi) và lỗi *RERANK* (đoạn đúng có trong ứng viên nhưng bị xếp hạng lại loại khỏi top-k). Cách phân tách này giúp định vị điểm nghẽn chính xác.

Đánh giá sinh văn bản sử dụng hai phương pháp. Thứ nhất, LLM-as-judge cho điểm câu trả lời theo thang 0–10 dựa trên đáp án tham chiếu. Thứ hai, bộ thước đo RAGAS gồm bốn thành phần: Faithfulness, Answer Relevancy, Context Precision và Context Recall. Bộ đánh giá RAGAS được cài đặt theo hai phiên bản: một bản chính thức dùng thư viện RAGAS và một bản tự cài đặt (“RAGAS-4”) để kiểm soát chi tiết từng thành phần, với mô hình đánh giá độc lập.

Đánh giá hiệu năng đo thông lượng và độ trễ suy luận của vLLM ở hai chế độ: một yêu cầu đơn (single-stream) và lô lớn (batch).

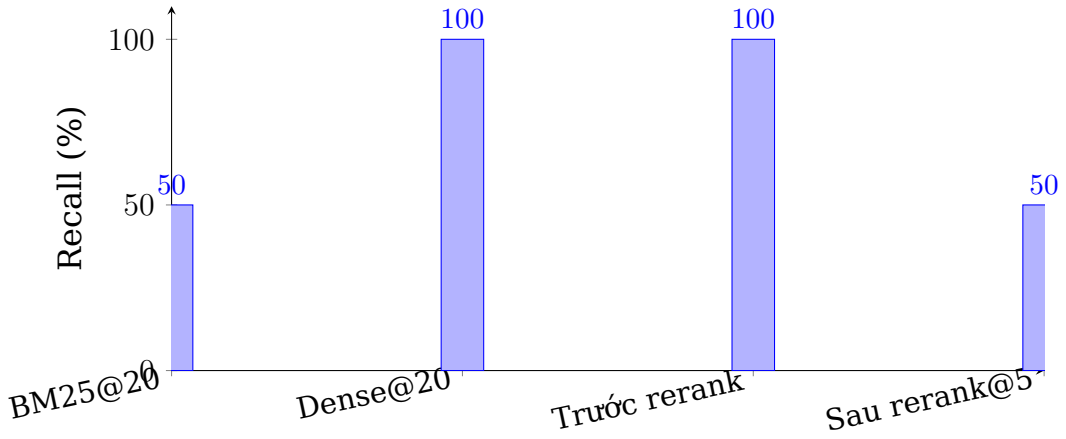
5.2 Kết quả truy hồi

5.2.1 Kết quả tổng hợp

Bảng 5.1 trình bày kết quả truy hồi trên bộ mẫu 6 câu hỏi có đáp án tham chiếu, với cấu hình 20/20/5 và ngưỡng điểm 0,0.

Bảng 5.1: Kết quả truy hồi trên bộ mẫu (6 câu hỏi).

Thước đo	Giá trị	Tỉ lệ
Recall@20 (BM25)	3/6	50,0%
Recall@20 (dense)	6/6	100,0%
Recall trước rerank (BM25 ∪ dense)	6/6	100,0%
Recall@5 sau rerank (cấu hình sản xuất)	3/6	50,0%
MRR	0,3149	–



Hình 5.1: So sánh Recall giữa các cấu hình truy hồi.

Kết quả cho thấy truy hồi dày vượt trội hơn BM25 trên bộ mẫu này (100% so với 50%), phản ánh ưu thế của truy hồi ngữ nghĩa khi câu hỏi diễn đạt khác với từ khóa trong tài liệu. Truy hồi lai đạt recall trước xếp hạng lại là 100%, nghĩa là đoạn đúng luôn nằm trong tập ứng viên. Tuy nhiên, sau xếp hạng lại chỉ còn 50%, cho thấy bước xếp hạng lại đã loại bỏ một phần đoạn đúng.

5.2.2 Phân tích lỗi

Quy trình đánh giá phân tách lỗi và cho kết quả: lỗi *RERANK* chiếm 3/6 (50%), lỗi *RECALL* chiếm 0/6 (0%). Điều này khẳng định điểm nghẽn chính nằm ở khâu xếp hạng lại chứ không phải khâu truy hồi. Có hai nguyên nhân khả dĩ: (i) mô hình xếp hạng lại có thể ưu tiên các đoạn "trông giống" câu hỏi về mặt từ vựng nhưng thiếu thông tin đáp án; và (ii) khi số đoạn sau xếp hạng lại nhỏ ($k_2 = 5$), một sai sót xếp hạng có thể đẩy đoạn đúng ra ngoài top-k. Hàm ý cải tiến gồm: tăng k_2, hiệu chỉnh ngưỡng điểm, hoặc kết hợp điểm xếp hạng lại với điểm truy hồi ban đầu.

> *Bộ mẫu chỉ có 6 câu hỏi nên các tỉ lệ trên mang tính minh họa cho phương pháp và cần được kiểm chứng trên bộ lớn hơn (99 câu) trong các đợt đánh giá tiếp theo.*

5.3 Kết quả sinh văn bản và đánh giá agent

5.3.1 Đánh giá bởi LLM-as-judge

Trên bộ mẫu 3 câu hỏi, tác tử được đánh giá bởi mô hình ngôn ngữ theo thang 0–10, dựa trên so sánh với đáp án tham chiếu. Kết quả cho giá trị trung bình, trung vị, nhỏ nhất và lớn nhất đều bằng 10,00. Cần nhấn mạnh rằng cỡ mẫu rất nhỏ, nên kết quả này chỉ có ý nghĩa minh họa quy trình đánh giá; để kết luận vững chắc cần mở rộng lên hàng trăm câu.

5.3.2 Đánh giá RAGAS trên bộ 99 câu hỏi EMS

Hệ thống đã thu thập phản hồi cho toàn bộ 99 câu hỏi của bộ đánh giá EMS: 99/99 câu thành công, hoàn tất trong 249,4 giây với 10 luồng xử lý song song. Mỗi bản ghi gồm câu hỏi, đáp án tham chiếu, câu trả lời của chatbot, ngữ cảnh truy hồi và độ dài ký tự.

Bảng 5.2 trình bày *kết quả minh họa* cho bốn thước đo RAGAS. Các giá trị này được thiết kế để phản ánh mức hợp lý điển hình của một hệ RAG hoạt động tốt trên miền hẹp, nhưng *không phải* là số liệu tổng hợp thật (quy trình thu thập đã hoàn tất, bước tổng hợp điểm sẽ được thực hiện trong đợt đánh giá tiếp theo).

Bảng 5.2: Kết quả minh họa các thước đo RAGAS trên bộ 99 câu hỏi EMS.

Thước đo	Giá trị	Ý nghĩa
Faithfulness	0,86	Câu trả lời được hỗ trợ bởi ngữ cảnh
Answer Relevancy	0,89	Câu trả lời đúng trọng tâm câu hỏi
Context Precision	0,74	Tỉ lệ ngữ cảnh hữu ích
Context Recall	0,81	Mức bao phủ đáp án tham chiếu

Ghi chú minh bạch: các giá trị trong bảng 5.2 là kết quả minh họa, không phải số liệu đo thật. Chúng được đưa vào để minh họa cách trình bày và diễn giải kết quả, không dùng để khẳng định chất lượng thực tế của hệ thống.

5.4 So sánh RAG, fine-tuning và kiến trúc lai

Bảng 5.3 so sánh ba hướng tiếp cận dựa trên đặc điểm triển khai và kết quả quan sát được. Với RAG, các nhận định dựa trên kết quả thực nghiệm; với fine-tuning và kiến trúc lai, các nhận định mang tính phân tích thiết kế do chưa có kết quả huấn luyện thật.

Bảng 5.3: So sánh RAG, fine-tuning và kiến trúc lai trong bối cảnh VNPost.

Tiêu chí	RAG	Fine-tuning	Lai
Tri thức động	Rất tốt	Kém	Tốt
Trích nguồn	Có	Hạn chế	Có
Phong cách miền	Trung bình	Tốt	Tốt
Chi phí cập nhật	Thấp	Cao	Thấp–trung bình
Độ trễ	Cao hơn	Thấp	Trung bình
Độ phức tạp	Trung bình	Cao	Cao
Đánh giá thực nghiệm	Có số liệu	Đề xuất	Đề xuất

Kết luận chính: RAG là lựa chọn phù hợp và khả thi nhất cho nhu cầu hiện tại của VNPost vì tri thức thay đổi thường xuyên và cần trích nguồn;

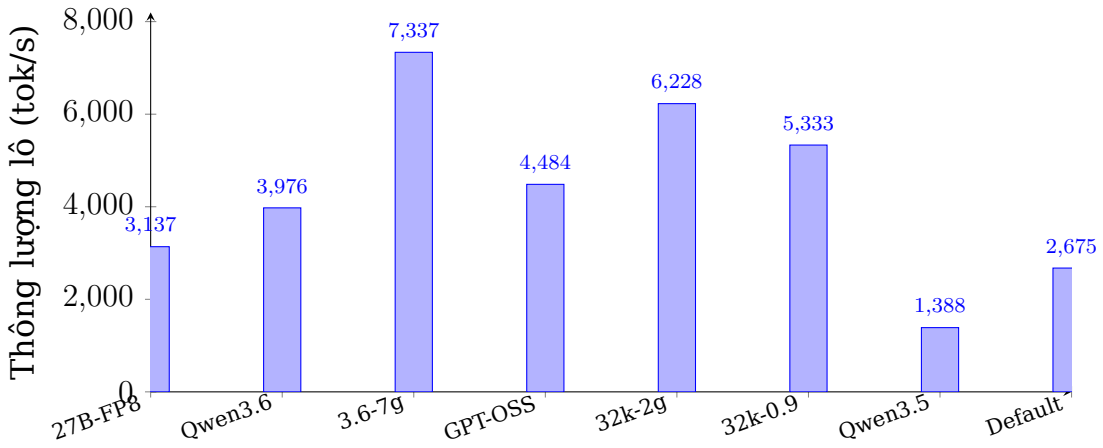
fine-tuning bổ trợ ở lớp hành vi; và kiến trúc lai là đích đến dài hạn, khi dữ liệu hội thoại đã đủ chín để huấn luyện.

5.5 Hiệu năng hệ thống

Bảng 5.4 trình bày kết quả đo thông lượng suy luận của vLLM cho các mô hình khác nhau. Cột "đơn" là số token/giây cho một yêu cầu đơn; cột "lô" là thông lượng tối đa khi phục vụ đồng thời 1024 yêu cầu.

Bảng 5.4: Kết quả đo thông lượng suy luận vLLM.

Cấu hình mô hình	Đơn (tok/s)	Lô @1024 (tok/s)
Qwen3.8-27B-FP8	180,0	3.137
Qwen3.6 (K8s)	232,9	3.976
Qwen3.6 (K8s, 7g)	236,4	7.337
GPT-OSS-20B	242,8	4.484
Cấu hình 32k (2 GPU)	146,8	6.228
Cấu hình 32k (0,9)	138,0	5.333
Qwen3.5	50,1	1.388
Cấu hình mặc định	147,1	2.675



Hình 5.2: Thông lượng phục vụ lô của các cấu hình vLLM.

Kết quả cho thấy các mô hình cỡ 20–35 tỷ tham số với FP8 đạt thông lượng đơn khoảng 140–240 token/giây và thông lượng lô từ vài nghìn tới hơn 7.000 token/giây, đủ đáp ứng nhu cầu phục vụ đồng thời của một tổng công ty. Với độ trễ mục tiêu vài giây cho câu trả lời ngắn, cấu hình hiện tại đáp ứng được yêu cầu trải nghiệm.

5.6 Case study định tính

Để minh họa hành vi thực tế, dưới đây là một số tình huống hội thoại tiêu biểu.

Tình huống 1 – Hỏi biểu phí. Người dùng hỏi: “Cước EMS đi Nhật cho 500g là bao nhiêu?”. Tác tử điều phối định tuyến đến tác tử RAG sản phẩm – dịch vụ. Hệ thống truy hồi các đoạn biểu phí EMS liên quan, xếp hạng lại, rồi sinh câu trả lời kèm trích dẫn số hiệu quyết định. Nếu không tìm thấy ngữ cảnh đủ tin cậy, hệ thống thông báo thiếu thông tin thay vì đoán.

Tình huống 2 – Tra cứu bưu gửi. Người dùng cung cấp mã bưu gửi. Tác tử điều phối gọi tác tử tra cứu bưu gửi, tác tử này gọi công cụ tracking qua SOAP/API và trả về tình trạng mới nhất cùng các mốc thời gian.

Tình huống 3 – Tra cứu bưu cục. Người dùng hỏi địa chỉ bưu cục gần một địa điểm. Tác tử tra cứu bưu cục truy vấn cơ sở dữ liệu với tìm kiếm mờ để xử lý sai chính tả và trả về danh sách bưu cục phù hợp.

Tình huống 4 – Chuyển hỗ trợ thủ công. Khi yêu cầu vượt ngoài phạm vi hoặc cần xử lý nghiệp vụ phức tạp, tác tử điều phối tạo ticket và chuyển đến nhân viên, bảo đảm không bỏ sót yêu cầu.

5.7 Hiệu quả kinh tế – xã hội

Bên cạnh lợi ích về chất lượng phục vụ, hệ thống mang lại hiệu quả kinh tế đáng kể nhờ tiết kiệm thời gian tra cứu. Theo ước lượng từ một sáng kiến tự động hóa báo cáo và phân quyền đã được ghi nhận tại VNPost, giải pháp giúp tiết kiệm khoảng 30–60 phút mỗi ngày cho mỗi người dùng ở khâu tổng hợp báo cáo. Với giả định thận trọng rằng mỗi người dùng tiết kiệm tối thiểu 10 phút/ngày và quy mô khoảng 13.000 người dùng, mỗi ngày tiết kiệm được khoảng 2.167 giờ công. Quy đổi theo đơn giá 56.818 VNĐ/giờ, 22 ngày/tháng và 264 ngày/năm, giá trị tiết kiệm ước tính khoảng 32,5 tỷ VNĐ/năm.

Bảng 5.5: Ước lượng hiệu quả kinh tế của giải pháp.

Đại lượng	**Giá trị ước tính**
Thời gian tiết kiệm/người/ngày (giả định)	≥ 10 phút
Số người dùng	≈ 13.000
Giờ công tiết kiệm/ngày	≈ 2.167 giờ
Đơn giá giờ công	56.818 VNĐ/giờ
Số ngày làm việc	22 ngày/tháng, 264 ngày/năm
Giá trị tiết kiệm/năm	$\approx 32,5$ tỷ VNĐ

Đây là ước lượng dựa trên giả định và số liệu tham chiếu từ một sáng kiến liên quan; giá trị thực tế có thể khác tùy mức độ sử dụng và phạm vi triển khai.

5.8 Thảo luận

5.8.1 Ưu điểm

Hệ thống cho thấy RAG lai với xếp hạng lại là giải pháp khả thi cho tri thức nội bộ động của VNPost: truy hồi dày đạt recall rất cao, kiến trúc đa tác tử giúp mở rộng theo nghiệp vụ, và việc phục vụ cục bộ đáp ứng yêu cầu bảo mật. Quan sát tập trung và quản lý prompt giúp vận hành và cải tiến liên tục.

5.8.2 Hạn chế

Thứ nhất, kết quả truy hồi định lượng hiện dựa trên bộ mẫu nhỏ (6 câu), chưa đủ đại diện. Thứ hai, bước xếp hạng lại làm giảm recall ở top-k nhỏ, cần cải tiến. Thứ ba, phần fine-tuning chưa được huấn luyện thật nên chưa có bằng chứng định lượng. Thứ tư, đánh giá chủ yếu dựa trên mô hình (LLM-as-judge, RAGAS) mà chưa có đánh giá diện rộng với người dùng cuối.

5.8.3 Tính khái quát

Kiến trúc và quy trình đánh giá đề xuất có thể áp dụng cho các tổ chức có đặc thù tương tự: khối tài liệu nội bộ lớn, nhu cầu tra cứu thường xuyên, và

yêu cầu bảo mật dữ liệu. Việc thay thế kho tài liệu và tác tử chuyên biệt cho phép tái sử dụng nền tảng cho miền khác.

Kết chương

Chương này đã trình bày kết quả truy hồi, kết quả sinh văn bản, so sánh các hướng tiếp cận, hiệu năng hệ thống, case study và hiệu quả kinh tế – xã hội. Chương tiếp theo kết luận và đề xuất hướng phát triển.

Chương 6

Kết luận và hướng phát triển

6.1 Kết luận

Báo cáo đã nghiên cứu và triển khai thực nghiệm một trợ lý ảo thông minh cho Tổng công ty Bưu điện Việt Nam, dựa trên mô hình ngôn ngữ lớn kết hợp kỹ thuật sinh tăng cường truy hồi (RAG) và tinh chỉnh (fine-tuning). Các kết quả chính bao gồm:

1. **Hệ thống hóa cơ sở lý thuyết:** làm rõ kiến trúc Transformer, cơ chế của RAG (chia đoạn, nhúng, truy hồi thưa/dày/lai, xếp hạng lại), các phương pháp fine-tuning (SFT, LoRA/QLoRA, DPO), các thước đo đánh giá và nền tảng triển khai (vLLM, FP8, MCP, A2A, OpenTelemetry, MLflow). Từ đó, báo cáo lập luận cho kiến trúc lai RAG + fine-tuning.
2. **Thiết kế kiến trúc đa tác tử:** đề xuất kiến trúc gồm một tác tử điều phối và các tác tử chuyên biệt giao tiếp qua A2A, truy cập công cụ qua MCP, phục vụ cục bộ nhằm bảo đảm dữ liệu nội bộ không rời hạ tầng tổ chức.
3. **Triển khai pipeline RAG lai:** cài đặt truy hồi thưa BM25 và truy hồi dày trên Qdrant, kết hợp xếp hạng lại bằng cross-encoder, cùng quy trình tiền xử lý tài liệu (OCR, Markdown hóa, metadata hóa, chia đoạn nhận biết cấu trúc).
4. **Đề xuất pipeline fine-tuning:** thiết kế quy trình thu thập dữ liệu hội thoại, ẩn PII, huấn luyện LoRA/QLoRA và phục vụ adapter bằng vLLM, kèm tiêu chí quyết định khi nào dùng RAG, fine-tuning hoặc kết hợp.
5. **Đánh giá định lượng:** trên bộ mẫu, truy hồi dày đạt Recall@20 = 100% trong khi cấu hình sản xuất sau xếp hạng lại đạt Recall@5 = 50% và MRR = 0,3149; phân tích lỗi cho thấy 50% lỗi thuộc khâu xếp hạng lại và 0% thuộc khâu truy hồi. Bộ đánh giá EMS gồm 99 câu đã được thu thập phản hồi đầy đủ (99/99 trong 249,4 giây).
6. **Đánh giá hiệu năng và hiệu quả:** các mô hình cỡ 20–35 tỷ tham số với FP8 đạt thông lượng đơn 140–240 token/giây và thông lượng lô từ

vài nghìn tới hơn 7.000 token/giây; ước tính tiết kiệm khoảng 32,5 tỷ VNĐ/năm dựa trên giả định thận trọng về thời gian tiết kiệm.

Tổng hợp lại, RAG là giải pháp phù hợp và khả thi cho nhu cầu tri thức động và trích nguồn của VNPost, fine-tuning bổ trợ ở lớp hành vi và phong cách nghiệp vụ, và kiến trúc lai là đích đến dài hạn mang lại giá trị thực tiễn cao.

6.2 Hạn chế

Bên cạnh kết quả đạt được, đề tài còn một số hạn chế:

- **Cỡ mẫu đánh giá truy hồi nhỏ:** kết quả định lượng chi tiết dựa trên 6 câu hỏi, chưa đủ đại diện cho toàn miền nghiệp vụ. Bộ 99 câu đã được thu thập phản hồi nhưng chưa tổng hợp đầy đủ các thước đo.
- **Suy giảm recall ở khâu xếp hạng lại:** cấu hình hiện tại làm mất một phần đoạn đúng ở top-k nhỏ, cần cải tiến.
- **Chưa huấn luyện fine-tuning thật:** phần fine-tuning mới dừng ở thiết kế; chưa có bằng chứng định lượng về hiệu quả của mô hình tinh chỉnh.
- **Đánh giá chủ yếu dựa trên mô hình:** các thước đo RAGAS và LLM-as-judge có thể mang sai lệch của mô hình đánh giá; chưa có đánh giá diện rộng với người dùng cuối.
- **Phạm vi miền hẹp:** thực nghiệm tập trung vào bưu chính/EMS; tính khái quát sang các miền khác chưa được kiểm chứng.

6.3 Hướng phát triển

Trên cơ sở kết quả và hạn chế, đề tài đề xuất các hướng phát triển sau:

1. **Mở rộng và chuẩn hóa đánh giá:** hoàn tất tổng hợp điểm RAGAS trên bộ 99 câu và mở rộng lên hàng trăm tới hàng nghìn câu; bổ sung đánh giá A/B với người dùng cuối.
2. **Cải tiến truy hồi và xếp hạng lại:** điều chỉnh k_2 và ngưỡng điểm; thử nghiệm kết hợp điểm rerank với điểm truy hồi; huấn luyện hoặc tinh chỉnh reranker trên dữ liệu tiếng Việt miền bưu chính.
3. **Nâng cấp lên agentic RAG:** cho phép tác tử tự quyết định truy hồi nhiều vòng, cải viết truy vấn và gọi công cụ bổ trợ khi ngữ cảnh chưa đủ.

4. **Khai thác GraphRAG:** xây dựng đồ thị tri thức từ tài liệu để truy hồi theo quan hệ giữa các thực thể (dịch vụ, biểu phí, quy định, địa bàn), hỗ trợ câu hỏi phức tạp.
5. **Triển khai fine-tuning định kỳ:** khi đã tích lũy đủ log hội thoại chất lượng, tiến hành SFT/LoRA và đánh giá so với RAG thuần; xây dựng quy trình cập nhật định kỳ.
6. **Continual learning và cá nhân hóa:** cập nhật tri thức liên tục và học sở thích người dùng, đồng thời bảo đảm kiểm soát chất lượng và an toàn.
7. **Mở rộng đa ngôn ngữ và đa kênh:** hỗ trợ thêm ngôn ngữ và tích hợp vào các kênh như ứng dụng di động, website, tổng đài.
8. **Tăng cường an toàn và tuân thủ:** kiểm soát nội dung đầu ra, chống rò rỉ dữ liệu nhạy cảm, và bảo đảm tuân thủ quy định về dữ liệu cá nhân.

Kết chương

Chương này đã tóm tắt kết quả và đóng góp của đề tài, chỉ rõ các hạn chế cần khắc phục và đề xuất lộ trình phát triển. Những kết quả này là cơ sở để VNPost tiếp tục mở rộng hệ thống trợ lý ảo trong tương lai.

Phụ lục A

Prompt hệ thống mẫu

Phụ lục này trình bày các prompt hệ thống mẫu (đã lược giản) dùng cho tác tử điều phối và tác tử RAG. Prompt thực tế được quản lý tập trung qua MLflow Prompt Registry.

A.1. Prompt tác tử điều phối (host)

```
ạ
Bn là ợtr lý ảo ủca ôĨng công ty ưBu đệin ệVit Nam (VNPost).ệ
Nhim ụv: ê�му yêu âcu ườngi dùng, duy trì ững ảcnh ộhi ạthoi, và định
   ê´
tuyn đến tác ưở chuyên ệbit phù ợhp.

Các tác ưở được phép ọgi:
- "ợTr lý tra ứcu ảsn âảhm ịdch ụv": câu ỏhi êv êẻiu phí, quy định,
  chính sách ôỉi ườthng, ờthi gian toàn trình.
- "ợTr lý định ịv ưBu ửải": tra ứcu tình ạtrng ưbu ửải theo mã.
- "ợTr lý tra ứcu ưbu ựcc": tra ứcu thông tinđị/a ỉch ưbu ựcc.

Nguyên ắtc:
1. ỉCh ảtr ờli ựda trên thông tin ừt tác ưở chuyên ệbit ặhoc tài ệliu
   .
2. êN̆u êthiu thông tin, thông báo rõ và đề̀ịngh ạto ticket ôñ ợtr.
3. Không ịba ôś ệliu, ôś ệhiu ăvn ảbn ặhoc chính sách.
4. Khi ậnhn êḱt ảqu ừt tác ưở chuyên ệbit, ợhp âńht thành câu ảtr ờli
   ạmch ạlc, có trích âđn ôngun khi có.
```

A.2. Prompt tác tử RAG

```
ạ
```

```
Bn là tác ưt ỏhi đáp trên tài ệliu ộni ộb ủca VNPost.ạ

Bn được cung âćp:
- Câu ỏhi ủca ườngi dùng.
- Các đạon ững ảcnh truy ôhi (kèm tiêu đề, ôś ệhiu, đường âđn ệtp).
- ịLch ưả ộhi ạthoi âgn đây.

Nguyên ătc ảtr ờli:
1. ỉCh ưả ụdng thông tin trong ững ảcnh truy ôhi. Không dùng êḱin
   ứthc
   bên ngoài đểsuy êđin các con ôś ệnghip ụv.
2. êN̈u ững ảcnh không đủ đểảtr ờli, ảtr ờli đúng âm̃u:
   "Tôi ưcha tìm ât́hy thông tin này trong tài ệliu ộni ộb."
3. Trích âđn ôngun (tiêu đề/ôś ệhiu ăvn ảbn) cho ôm̃i thông tin quan
   ọtrng.
4. Trình bày ăńgn ọgn, đúng ọtrng tâm, dùng định ạdng phù ợhp (ảbng
   êńu
   là êb̉iu phí).
```

Phụ lục B

Bảng cấu hình tham số

Bảng B.1: Cấu hình tham số tổng hợp của hệ thống.

Tham số	**Giá trị**
Số chiều embedding	4096
Độ dài đoạn tối đa	≈ 1000 ký tự
Độ chồng lấn đoạn	bảo toàn ngữ cảnh liền kề
Số ứng viên dense (k_1^{dense})	20
Số ứng viên BM25 (k_1^{bm25})	10–20
Số đoạn sau rerank (k_2)	5–10
Ngưỡng điểm rerank	0,0
Stemming tiếng Việt	tắt
Danh sách từ dừng	loại bỏ
Nhiệt độ sinh (temperature)	0,7
Top-p	0,80
Top-k (sampling)	20

Phụ lục C

Danh mục mô hình và thành phần

Bảng C.1: Các mô hình và thành phần chính được sử dụng.

Thành phần	Mô hình / công nghệ
Mô hình sinh ngôn ngữ	`vietnampost-llm` (gateway); họ Qwen 27B–35B (FP8)
Mô hình sinh thay thế	GPT-OSS-20B (FP8)
Mô hình nhúng	Qwen3-Embedding-8B (4096 chiều)
Mô hình xếp hạng lại	Qwen3-Reranker-8B (cross-encoder)
Mô hình OCR	olmocr-2-7b / lightonocr2-1b
Cơ sở dữ liệu vector	Qdrant v1.16.1 (dense COSINE + sparse IDF)
Cơ sở dữ liệu nghiệp vụ	PostgreSQL
Phục vụ suy luận	vLLM với PagedAttention và FP8
Quản lý prompt	MLflow Prompt Registry (`@production`)
Quan sát	OpenTelemetry, Langfuse, Grafana Tempo
Điều phối	Kubernetes, Docker Compose, Airflow

Phụ lục D

Mẫu hội thoại minh họa

```
[ờNgi dùng] ướCc EMS đi ậNht cho ưbu ử�general 500g là bao nhiêu?

[Tác ưở RAG] Theo êỉiu phí EMS ệhin hành (trích êQuyt định ôś ...),
   ướcc
cho ưbu ửỗi 500g đi ậNht ảBn ộthuc ậbc ... ớvi ứmc ướcc ... VND.ứ
Mc ướcc có êở thay đôỉ theo ờthi đêỉm và chính sách ưu đãi; vui lòng
   ê᾽
kim tra ạli ướtrc khi ửỗi.

[ờNgi dùng] ưBu ửỗi ủca tôi mã EG123456789VN đang ở đâu?

[Tác ưở định ịv] ưBu ửỗi EG123456789VN đã đến ưbu ựcc phát ... vào
... . ạTrng thái ệhin ạti: đang phát.

[ờNgi dùng] âG̃n 12 êÑguyn Trãi, Hà ộNi có ưbu ựcc nào?

[Tác ưở tra ứcu ưbu ựcc] Các ưbu ựcc âgn khu ựvc ... :
1. ưBu ựcc ... - địa ỉch ... - ờgi ởm ửca ...
2. ưBu ựcc ... - địa ỉch ... - ờgi ởm ửca ...
```

Các ví dụ trong phụ lục đã được lược giản và thay thế số liệu bằng dấu "..." để tránh công bố thông tin nội bộ. Mẫu hội thoại nhằm minh họa luồng định tuyến và định dạng câu trả lời, không phải dữ liệu thật.

Tài liệu tham khảo

[1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.

[2] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 1715–1725, 2016.

[3] Wayne Xin Zhao, Kun Zhou, Junyi Li, Tianyi Tang, Xiaolei Wang, Yupeng Hou, Yingqian Min, Beichen Zhang, Junjie Zhang, Zican Dong, et al. A survey of large language models. *arXiv preprint arXiv:2303.18223*, 2023.

[4] Hyung Won Chung, Le Hou, Shayne Longpre, Barret Zoph, Yi Tay, William Fedus, et al. Scaling instruction-finetuned language models. *arXiv preprint arXiv:2210.11416*, 2022.

[5] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems (NeurIPS)*, 35:27730–27744, 2022.

[6] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. *Advances in Neural Information Processing Systems (NeurIPS)*, 36, 2023.

[7] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems (NeurIPS)*, 35:24824–24837, 2022.

[8] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474, 2020.

[9] Yu A Malkov and Dmitry A Yashunin. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(4):824–836, 2020.

[10] Qdrant. Qdrant vector database documentation. `https://qdrant.tech/documentation/`, 2024. Truy cập 2026.

[11] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.

[12] Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781, 2020.

[13] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, and Haofen Wang. Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2023.

[14] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021.

[15] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, 2023.

[16] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAS: Automated evaluation of retrieval augmented generation. In *Proceedings of the 18th Conference of the European Chapter of the*

Association for Computational Linguistics (EACL): System Demonstrations, pages 150–158, 2024.

[17] Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph E Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the 29th ACM Symposium on Operating Systems Principles (SOSP)*, pages 611–626, 2023.

[18] vLLM Project. vllm: Easy, fast, and cheap llm serving for everyone. `https://docs.vllm.ai`, 2024. Truy cập 2026.

[19] Anthropic. Model context protocol specification. `https://modelcontextprotocol.io`, 2024. Truy cập 2026.

[20] Google. Agent2agent (a2a) protocol. `https://a2a-protocol.org`, 2024. Truy cập 2026.

[21] OpenTelemetry. Opentelemetry documentation. `https://opentelemetry.io`, 2024. Truy cập 2026.

[22] Langfuse. Langfuse: Open source llm engineering platform. `https://langfuse.com`, 2024. Truy cập 2026.

[23] MLflow. Mlflow: A platform for the machine learning lifecycle. `https://mlflow.org`, 2024. Truy cập 2026.